



ANÁLISE EXPLORATÓRIA DE DADOS

AULA 5



Prof. Dayane Perez Bravo



CONVERSA INICIAL

Nesta aula, iremos aprender sobre alguns tipos de médias e formas de descrever a dispersão dos dados.

TEMA 1 – MÉDIAS

Não existe uma forma única de calcular a média de um determinado conjunto de dados. Vejamos algumas das médias existentes e como elas se aplicam para interpretá-los.

1.1 Média Ponderada

A definição de **média ponderada** é feita a partir de um fator p_k que considera o peso de cada uma das observações x_k . Dessa forma, observações diferentes devem possuir um impacto maior ou menor no resultado final. Definimos tal média a partir de:

$$\text{média ponderada} = \sum_{k=1}^m x_k p_k / \sum_{k=1}^m p_k$$

para um conjunto de m dados.

Para compreender o uso da média ponderada, considere a existência de um sistema de avaliação progressivo, em que as avaliações seguintes acumulam uma maior parte de conteúdos e, por consequência, refletem mais adequadamente o aprendizado dos alunos.

Considere dois alunos que obtiveram as seguintes notas nas avaliações:

$A - 2 \ 5 \ 8 \ 10$

$B - 10 \ 8 \ 5 \ 2$

Note que, em ambos os casos, a partir da média aritmética, o resultado de ambos foi igual. Entretanto, podemos notar que houve uma progressão em relação ao aluno A , que se desenvolveu ao longo do curso, enquanto houve uma regressão em relação ao aluno B , que teve um desempenho decrescente ao longo das avaliações.

Para representar que as notas posteriores são mais importantes que as anteriores, podemos utilizar um sistema de peso, refletindo essa importância, como indicado na Tabela 1.



Tabela 1 – Peso de cada uma das avaliações

Avaliação (x_k)	Peso (p_k)
Avaliação 1	1
Avaliação 2	2
Avaliação 3	3
Avaliação 4	4

Fonte: Bravo, 2020.

Assim, podemos calcular a média ponderada de cada um desses alunos, obtendo:

$$\overline{x}_A = \frac{1.2 + 2.5 + 3.8 + 4.10}{10} = 7,6$$

$$\overline{x}_B = \frac{1.10 + 2.8 + 3.5 + 4.1}{10} = 4,5$$

Agora, esse novo resultado mostra a progressão do aluno *A* e a regressão do aluno *B*, representando, de forma mais adequada, o que ocorreu na realidade.

1.2 Média geométrica

Em dados que possuem um comportamento geométrico, i.e., se comportam aproximadamente como uma progressão geométrica, é interessante utilizar a **média geométrica** para uma representação adequada dos dados. Nesse caso, temos:

$$\overline{x}_g = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$

Veja, por exemplo, que no caso de uma progressão geométrica de razão 2, de 5 termos, como se segue:

$$2, 4, 8, 16, 32$$

Temos que:

$$\overline{x}_g = \sqrt[5]{2 \cdot 4 \cdot 8 \cdot 16 \cdot 32} = 8.$$

Que é uma representação mais adequada do que:

$$\bar{x} = \frac{2 + 4 + 8 + 16 + 32}{5} = 12,4$$



1.2 Média harmônica

Quando o numerador dos dados forma, aproximadamente, uma progressão aritmética, é interessante utilizar a média harmônica para uma representação adequada dos dados.

Considere, por exemplo, os seguintes dados:

$$1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \frac{1}{5}$$

Tais dados, atendem, perfeitamente, ao requisito para utilizarmos a média harmônica. Nesse caso, a definimos como:

$$\bar{x}_h = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Assim, temos:

$$\bar{x}_h = \frac{5}{\frac{1}{1} + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5}} = \frac{5}{15} = 0,33 \dots$$

1.2 Exemplo

Considere um estudante que obteve nota 85 na primeira prova, 35 na segunda, 45 na terceira e 45 na última. Note que, nesse caso, a partir da média aritmética teria:

$$\bar{x} = \frac{85 + 35 + 45 + 45}{4} = 52,5$$

Entretanto, se as provas tiverem pesos, como a seguir: 1 para a primeira prova, 2 para a segunda, 2 para a terceira e 3 para a quarta; então:

$$\bar{x} = \frac{1.85 + 2.35 + 2.45 + 3.45}{8} = 47,5$$

Caso a média para aprovação fosse 50, uma das médias não o aprovaria.

Definimos os **quartis** como os valores que dividem o conjunto de dados ordenados em quatro partes iguais. O processo é semelhante ao realizado com a mediana que, por sua vez, dividia o conjunto de dados ordenados em duas partes iguais. No caso do quartil, cada parte conterá, conseqüentemente, 25% dos dados.

2.1 Primeiro e terceiro quartis

Podemos determinar a posição do primeiro e do terceiro quartis, a partir de uma relação simples:

$$i_{Q_1} = (n + 1) \cdot \frac{1}{4}$$

$$i_{Q_3} = (n + 1) \cdot \frac{3}{4}$$

Assim, considerando os seguintes dados ($n = 8$):

11,11,13,13,15,16,19,21

Podemos calcular o primeiro quartil, isto é:

$$i_{Q_1} = (8 + 1) \cdot \frac{1}{4} = 2,25$$

Nesse caso, observamos que sua posição está entre o segundo e o terceiro dado. Agora, para encontrar seu valor, realizamos:

$$Q_1 = 11 + (13 - 11) \cdot 0,25 = 11,5$$

No caso do terceiro quartil, temos:

$$i_{Q_3} = (8 + 1) \cdot \frac{3}{4} = 6,75$$

Assim, encontra-se entre o sexto e o sétimo termo. E realizamos:

$$Q_3 = 16 + (19 - 16) \cdot 0,75 = 18,25$$

Para o conjunto de dados em que $n = 9$:

12 14 16 18 20 22 24 26 28

Temos:

$$i_{Q_1} = (9 + 1) \cdot \frac{1}{4} = 2,5$$



$$Q_1 = 14 + (16 - 14) \cdot 0,5 = 15$$

$$i_{Q_3} = (9 + 1) \cdot \frac{3}{4} = 7,5$$

$$Q_3 = 24 + (26 - 24) \cdot 0,5 = 25$$

2.2 Primeiro e terceiro quartis para dados discretos em tabelas de frequência

Considere os dados descritos pela Tabela 2.

Tabela 2 – Exemplo de dados discretos em tabelas de frequência

k	x_k	$f(x_k)$	$F(x_k)$
1	10	2	2
2	11	5	7
3	12	10	17
4	13	9	26
5	14	5	31
6	15	3	34
Σ		34	

Fonte: Bravo, 2020.

Nesse caso, procedemos de forma equivalente, obtendo a posição do primeiro quartil e seu valor:

$$i_{Q_1} = (34 + 1) \cdot \frac{1}{4} = 8,75$$

$$Q_1 = 12 + (12 - 12) \cdot 0,75 = 12$$

E a posição do terceiro quartil e seu valor:

$$i_{Q_3} = (34 + 1) \cdot \frac{3}{4}$$

$$Q_3 = 13 + (14 - 13) \cdot 0,25 = 13,25$$



2.3 Primeiro e terceiro quartis para dados contínuos em tabelas de frequência

Quando temos dados contínuos separados em classes, precisamos nos atentar a determinar em qual classe está contido cada um dos quartis e realizar uma aproximação para o seu valor.

Dessa forma, precisamos encontrar em qual classe k , $F(x_k)$ torna-se maior ou igual a $\frac{n}{4}$ ou $\frac{3n}{4}$. Sendo igual a um desses valores, o respectivo quartil será o limite superior da classe k . Sendo maior, utilizaremos as expressões:

$$Q_1 = x_{k(inf)} + \frac{\left[\frac{n}{4} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$
$$Q_3 = x_{k(inf)} + \frac{\left[\frac{3n}{4} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

Por exemplo, para os dados descritos pela Tabela 3, podemos encontrar o primeiro e o terceiro quartis.

Tabela 3 – Exemplo utilizado para cálculo dos quartis a partir de tabela de frequência para dados contínuos

k	Classe	$f(x_k)$	$F(x_k)$
1	0,0 – 2,0	3	3
2	2,0 – 4,0	6	9
3	4,0 – 6,0	12	21
4	6,0 – 8,0	9	30
5	8,0 – 10,0	6	36
Σ		36	

Fonte: Bravo, 2020.

Para o cálculo do primeiro quartil, note que:

$$i_{Q_1} = \frac{n}{4} = \frac{36}{4} = 9$$

Indicando que $Q_1 = 4,0$, visto que a posição do primeiro quartil é igual à frequência acumulada da segunda classe.

Para o cálculo do terceiro quartil, note que:



$$i_{Q_3} = \frac{3n}{4} = \frac{3 \cdot 36}{4} = 27$$

Indicando que o terceiro quartil está na quarta classe. Como sua posição não é igual à frequência acumulada dessa classe, devemos calculá-lo:

$$Q_3 = x_{k(inf)} + \frac{\left[\frac{3n}{4} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

$$Q_3 = 6,0 + \frac{[27 - 21] \cdot (8,0 - 6,0)}{30 - 21} = 7,3$$

TEMA 3 – PERCENTIL

De forma equivalente ao quartil e a mediana, podemos utilizar o percentil para dividir o conjunto de dados em uma determinada parcela. No caso do percentil, iremos dividi-la em 100 grupos contendo a mesma quantidade de dados em cada um.

Como notação usamos P_p indicando, por exemplo, que P_{15} indica que 15% dos dados estão distribuídos à esquerda e 85% à direita de P_{15} . Note que P_{25} indica o primeiro quartil, enquanto P_{50} indica o segundo quartil ou a mediana e P_{75} indica, por sua vez, o terceiro quartil.

3.1 Posição e cálculo dos percentis

A estratégia para calcular a posição e o valor dos percentis é equivalente ao realizado no cálculo da mediana e dos quartis, com uma pequena adaptação. Nesse caso, definimos:

$$i_p = (n + 1) \cdot \frac{p}{100}$$

Assim, por exemplo, sendo as seguintes observações:

13 14 16 16 17 18 19 20 21 22 24 26

Temos um total de $n = 12$ dados e podemos encontrar, por exemplo:

$$i_{10} = (12 + 1) \cdot \frac{10}{100} = 1,3$$

$$P_{10} = 13 + (14 - 13) \cdot 0,3 = 13,3$$

Ou ainda:



$$i_{25} = (12 + 1) \cdot \frac{25}{100} = 3,25$$

$$P_{25} = 16 + (16 - 16) \cdot 0,25 = 16$$

3.2 Percentis para dados contínuos em tabelas de frequência

Para dados contínuos em tabelas de frequência, ou seja, agrupados em classe, realizamos um procedimento similar ao realizado com os quartis, identificando em qual classe o percentil respectivo está inserido.

Caso o percentil esteja ao final da classe, ou seja, o cálculo de sua posição é o mesmo valor da frequência acumulada, utilizamos o limite superior da classe como o percentil. Caso contrário, usaremos da expressão a seguir:

$$P_p = x_{k(inf)} + \frac{\left[\frac{pn}{100} - F(x_{k-1}) \right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

Então considere os dados descritos na Tabela 4, a seguir.

Tabela 4 – Dados para o cálculo de percentil de uma tabela de frequência de dados contínuos

<i>k</i>	Classe	$f(x_k)$	$F(x_k)$
1	4,85 – 4,90	3	3
2	4,90 – 4,95	6	9
3	4,95 – 5,00	12	21
4	5,00 – 5,05	9	30
5	5,05 – 5,10	6	36
Σ		36	

Fonte: Bravo, 2020.

Veja, por exemplo, o cálculo de P_{15} . Primeiro, identificamos a posição em que se encontra:

$$i_{p_{15}} = \frac{p \cdot n}{100} = \frac{15 \cdot 36}{100} = 5,4$$

Note que está incluído dentro da segunda classe. Assim, calculamos:

$$P_p = x_{k(inf)} + \frac{\left[\frac{pn}{100} - F(x_{k-1}) \right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$



$$P_{15} = 4,90 + \frac{[5,4 - 3] \cdot (4,95 - 4,90)}{9 - 3} = 4,92$$

De forma equivalente, podemos encontrar P_{90} . Sua posição é dada por:

$$i_{p_{90}} = \frac{p \cdot n}{100} = \frac{90 \cdot 36}{100} = 32,4$$

Podemos verificar que esse dado está incluso na quinta classe. Assim, calculamos:

$$P_p = x_{k(inf)} + \frac{\left[\frac{pn}{100} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

$$P_{90} = 5,05 + \frac{[32,4 - 30] \cdot (5,10 - 5,05)}{36 - 30} = 5,07$$

A expressão que calcula o percentil pode ser utilizada para respondermos outro tipo de pergunta, como, por exemplo, quantos dados são maiores ou iguais a 4,93, ou quantos dados são menores que 5,07. Nesses casos, fazemos da seguinte forma: como 4,93 pertence a segunda classe, realizamos:

$$P_p = x_{k(inf)} + \frac{\left[\frac{pn}{100} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

$$4,93 = 4,90 + \frac{\left[\frac{p \cdot 36}{100} - 3\right] \cdot (4,95 - 4,90)}{9 - 3}$$

$$p = 18,33$$

Mostrando que 18,33% dos dados estão abaixo de 4,93 ou, de forma equivalente, 81,67% deles são iguais ou maiores que 4,93. Como 5,07 pertence à terceira classe, realizamos:

$$P_p = x_{k(inf)} + \frac{\left[\frac{pn}{100} - F(x_{k-1})\right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

$$5,07 = 5,05 + \frac{\left[\frac{p \cdot 36}{100} - 30\right] \cdot (5,10 - 5,05)}{36 - 30}$$

$$p = 90$$

Mostrando que 90% dos dados estão abaixo de 5,07.



TEMA 4 – MEDIDAS DE DISPERSÃO

O uso das médias, medianas, modas, quartis ou percentis nem sempre são suficientes para descrever determinado conjunto de dados. Para verificar isso, basta notar que:

$$A - 10 \ 11 \ 11 \ 11 \ 12 \ 12 \ 12 \ 12 \ 13 \ 14 \ 14$$

$$B - 1 \ 5 \ 6 \ 9 \ 11 \ 12 \ 12 \ 15 \ 18 \ 21 \ 22$$

possuem as mesmas características descritas, mas são dados completamente diferentes em relação às suas **dispersões**. Nesta seção, iremos discutir as **medidas de dispersão**.

4.1 Amplitude

Definimos **amplitude** como a diferença entre o maior e o menor valor de um conjunto de dados, i.e.,

$$\text{Amplitude} = (\text{Máximo}) - (\text{Mínimo})$$

Por exemplo, para os dados do exemplo:

$$A_A = 14 - 10 = 4$$

$$A_B = 22 - 1 = 21$$

Isso já nos traz uma interpretação de que o conjunto de dados B é mais disperso que A .

4.2 Intervalo interquartil

Podemos encontrar o **intervalo interquartil** como:

$$\text{Intervalo Interquartil} = Q_3 - Q_1$$

No caso do conjunto de dados A , $Q_1 = 11$ e $Q_3 = 13$ e Intervalo Interquartil = 2. No caso do conjunto de dados B , $Q_1 = 6$, $Q_3 = 18$ e Intervalo Interquartil = 12, indicando, mais uma vez, a dispersão maior do conjunto de dados B .

4.3 Desvio médio absoluto

O **desvio** é conhecido, em estatística, como a diferença de determinado valor de sua média, i.e.,



$$\text{desvio} = x_i - \bar{x}$$

Geralmente, estamos interessados em determinar a soma de todos os desvios. Entretanto, note que:

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = n\bar{x} - n\bar{x} = 0$$

Assim, a soma dos desvios não é interessante da forma apresentada, visto que não apresenta conclusão nenhuma dos dados. Isso acontece porque os termos negativos do desvio se anulam com os termos positivos no somatório.

Uma primeira estratégia é calcular o módulo de cada um dos desvios para definirmos o **desvio médio absoluto**:

$$DM = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Note que, para os dados do conjunto A e do conjunto B , $\bar{x} = 12$. Assim, calculamos:

$$DM_A = \frac{|10 - 12| + |11 - 12| + \dots + |14 - 12|}{11} = 0,8333 \dots$$
$$DM_B = \frac{|1 - 12| + |5 - 12| + \dots + |22 - 12|}{11} = 5,0909 \dots$$

Note que esse indicativo é forte para indicar a dispersão de um conjunto de dados, mas, costumamos usar o **desvio padrão** e a **variância** para descrever ainda mais adequadamente essa dispersão.

TEMA 5 – VARIÂNCIA E DESVIO PADRÃO

A estratégia mais utilizada para contornar o fato de que a soma dos desvios é igual a zero é, ao invés de utilizar o módulo, elevar cada um dos desvios ao quadrado. Quando fazemos isso, encontramos a **variância** dos dados.

5.1 Variância

Denota-se a **variância** como σ^2 para a **variância populacional** e s^2 como a **variância amostral**. Para o cálculo de ambos, devemos somar os quadrados de cada um dos desvios e dividir pelo tamanho da população, N ou pelo tamanho da amostra, n , respectivamente. Isto é:



$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Para compreender seu cálculo, veja o seguinte conjunto de dados:

11 16 12 14 13

Podemos calcular sua média:

$$\bar{x} = \frac{11 + 16 + 12 + 14 + 13}{5} = 11,2$$

E calcular a variância amostral:

$$s^2 = \frac{(11 - 11,2)^2 + (16 - 11,2)^2 + (12 - 11,2)^2 + (14 - 11,2)^2 + (13 - 11,2)^2}{5 - 1}$$

$$s^2 = 8,7$$

A variância é uma ótima medida de dispersão, mas em vários casos não é escolhida para descrever adequadamente essa dispersão. Para compreender o porquê, lembre-se que os dados costumam vir com uma determinada unidade de medida (i.e., metro, quilograma, reais, alunos...). Quando realizamos o cálculo da variância, elevamos os desvios ao quadrado, de forma que a unidade de medida da variância difere-se dos dados originais (i.e., metro ao quadrado, quilograma ao quadrado, reais ao quadrado...).

5.2 Desvio padrão

Para contornar essa dificuldade, simplesmente calculamos a raiz quadrada da variância e a definimos como **desvio padrão**. Essa medida é uma das mais importantes na descrição de um conjunto de dados.

Por exemplo, suponha que um fabricante de tortas pesou sete delas e obteve as seguintes medidas:

1,2 1,3 1,4 1,2 1,3 1,5 1,3

Todas em quilogramas (*kg*). Nesse caso, podemos calcular a média amostral:

$$\bar{x} = \frac{1,2 + 1,3 + 1,4 + 1,2 + 1,3 + 1,5 + 1,3}{7} = 1,3 \text{ kg}$$

E a variância amostral:



$$s^2 = \frac{(1,2 - 1,3)^2 + (1,3 - 1,3)^2 + \dots + (1,3 - 1,3)^2}{7 - 1} = 0,01 \text{ kg}^2$$

Note a sua unidade de medida. Assim, calculamos o desvio padrão:

$$s = \sqrt{s^2} = \sqrt{0,01} = 0,1 \text{ kg}$$

5.3 Exemplo

Considere três candidatos a executarem determinado serviço. Para a escolha do candidato, decide-se pelo candidato mais rápido. Assim, extraiu-se 7 amostras do tempo de cada um deles, como apresentado na Tabela 5.

Tabela 5 – Tempo de cada candidato para executar determinado serviço

Candidato	Tempo (min)						
A	12,5	13,6	12,8	13,5	12,8	12,9	13,0
B	15,5	18,2	15,6	14,5	16,5	18,2	14,5
C	12,8	10,5	15,2	16,5	9,9	12,5	13,0

Fonte: Bravo, 2020.

Podemos calcular a média de cada um dos candidatos:

$$\bar{x}_A = \frac{12,5 + 13,6 + \dots + 13,0}{7} = 13,01 \text{ min}$$

$$\bar{x}_B = \frac{15,5 + 18,2 + \dots + 14,5}{7} = 16,14 \text{ min}$$

$$\bar{x}_C = \frac{12,8 + 10,5 + \dots + 13,0}{7} = 12,91 \text{ min}$$

Isso nos indica que o tempo médio de C é mais rápido do que os outros candidatos. Para esses dados, podemos encontrar as variâncias amostrais:

$$s_A^2 = \frac{(12,5 - 13,01)^2 + (13,6 - 13,01)^2 + \dots + (13,0 - 13,01)^2}{7 - 1} = 0,987 \text{ (min)}^2$$

$$s_B^2 = \frac{(15,5 - 16,14)^2 + (18,2 - 16,14)^2 + \dots + (14,5 - 16,14)^2}{7 - 1} = 14,6972 \text{ (min)}^2$$

$$s_C^2 = \frac{(12,8 - 12,91)^2 + (10,5 - 12,91)^2 + \dots + (13,0 - 12,91)^2}{7 - 1} = 33,1887 \text{ (min)}^2$$

E podemos encontrar os desvios padrões:

$$s_A = \sqrt{0,987} = 0,9740 \text{ min}$$



$$s_B = \sqrt{14,6972} = 3,8337 \text{ min}$$

$$s_C = \sqrt{33,1887} = 5,760963 \text{ min}$$

Note que, observando os dados, por mais que o candidato C tenha uma média menor, como não há consistência em seu tempo, podemos afirmar que o candidato A deveria ser selecionado.

FINALIZANDO

Aprendemos, nesta aula, a descrever determinado conjunto de dados a partir da análise da sua dispersão.



REFERÊNCIAS

CASTANHEIRA, N. P. **Estatística aplicada a todos os níveis**. Curitiba: InterSaberes, 2012.

CASTANHEIRA, N. P. **Métodos Quantitativos**. Curitiba: InterSaberes, 2013.

DOWNING, D.; CLARK, J.; **Estatística aplicada**. 3. ed. São Paulo: Saraiva, 2010.

FREUND, J. E.; **Estatística aplicada**. 11. ed. Porto Alegre: Bookman, 2007.

LARSON, R.; FARBER, B.; **Estatística aplicada**. 6. ed. São Paulo: Pearson, Education do Brasil, 2015.

MONTGOMERY, D. C.; RUNGER, G. C.; **Estatística aplicada e probabilidade para engenheiros**. 5. ed. Rio de Janeiro: LTC, 2012.

MONTGOMERY, D. C.; RUNGER, G. C.; HUBELE, N. F.; **Estatística aplicada à engenharia**. 2. ed. Rio de Janeiro: LTC, 2013.

SIQUEIRA, J. O. **Fundamentos de Métodos Quantitativos**. São Paulo: Saraiva, 2011.