



ANÁLISE EXPLORATÓRIA DE DADOS

AULA 6



Prof. Dayane Perez Bravo



CONVERSA INICIAL

Nesta aula iremos discutir, inicialmente, como facilitar o cálculo da variância para dados contínuos e discretos descritos em tabela de frequência. Na sequência iremos definir os tipos de distribuições de dados que podem surgir em relação a sua simetria e a sua curtose.

TEMA 1 – VARIÂNCIA PARA DADOS DISCRETOS E CONTÍNUOS EM TABELA DE FREQUÊNCIA

Inicialmente, iremos determinar uma estratégia para facilitar, com o uso de tabelas, o cálculo da variância tanto para dados discretos como para dados contínuos.

1.1 Expressões para a variância em dados discretos

Variância populacional é simbolizada pelo uso de σ^2 . Quando os dados estão apresentados em uma tabela de frequência e são discretos, utilizamos:

$$\sigma^2 = \frac{\sum_{k=1}^m [(x_k - \mu)^2 \cdot f(x_k)]}{N}$$

Em que N representa a quantidade de dados da população e μ representa a média populacional. Como, em uma tabela de frequência, o mesmo dado pode aparecer mais de uma vez, m representa a quantidade de possibilidades entre os valores de x_k , enquanto $f(x_k)$ representa a frequência, i.e., a quantidade de observações, do evento x_k .

Geralmente é complicado, quando não impossível, coletar dados de toda a população. Assim, extraímos uma amostra e, para as condições descritas, encontramos a variância amostral, s^2 , dada por:

$$s^2 = \frac{\sum_{k=1}^m [(x_k - \bar{x})^2 \cdot f(x_k)]}{n - 1}$$

Em que n representa a quantidade de dados da amostra e $\bar{x}$ representa a média populacional.



1.2 Procedimento para o cálculo da variância

Para esse cálculo, considere os dados distribuídos em uma tabela de frequência como apresentado na Tabela 1.

Tabela 1 – Dados discretos em tabela de frequência

x_k	$f(x_k)$
2	1
4	3
5	4
6	2
Σ	10

Para isso, inicialmente, calculamos a média:

$$\bar{x} = \frac{\sum_{k=1}^m x_k \cdot f(x_k)}{n}$$

E expandimos a tabela de frequência para a Tabela 2:

Tabela 2 – Tabela de auxílio para o cálculo da média

x_k	$f(x_k)$	$x_k \cdot f(x_k)$
2	1	2
4	3	12
5	4	20
6	2	12
Σ	10	46

Assim,

$$\bar{x} = \frac{\sum_{k=1}^m x_k \cdot f(x_k)}{n} = \frac{46}{10} = 4,6$$

Agora, para o cálculo da variância, podemos expandir a Tabela 2 para gerar a Tabela 3, que auxilia nesse cálculo.



Tabela 3 – Tabela de auxílio para o cálculo da variância

x_k	$f(x_k)$	$x_k \cdot f(x_k)$	$x_k - \bar{x}$	$(x_k - \bar{x})^2$	$(x_k - \bar{x})^2 \cdot f(x_k)$
2	1	2	-2,6	6,76	6,76
4	3	12	-0,6	0,36	1,08
5	4	20	0,4	0,16	0,64
6	2	12	1,4	1,96	3,92
Σ	10	46			12,40

Assim,

$$s^2 = \frac{\sum_{k=1}^m [(x_k - \bar{x})^2 \cdot f(x_k)]}{n - 1} = \frac{12,40}{10 - 1} = 1,4$$

E o desvio padrão é dado por:

$$s = \sqrt{1,4} = 1,2$$

1.3 Expressões para a variância em dados contínuos

A diferença em relação à variância para dados discretos é que, no caso dos dados contínuos, tais informações estão descritas a partir de classes. Então, substituímos as observações x_k pelo ponto médio da classe $\bar{x}_k$. Assim,

$$\sigma^2 = \frac{\sum_{k=1}^m [(\bar{x}_k - \mu)^2 \cdot f(x_k)]}{N}$$

representa a variância populacional, enquanto

$$s^2 = \frac{\sum_{k=1}^m [(\bar{x}_k - \bar{x})^2 \cdot f(x_k)]}{n - 1}$$

representa a variância amostral.

1.4 Cálculo da variância

Como exemplo, considere os dados descritos na Tabela 4.



Tabela 4 – Exemplo de dados contínuos para o cálculo da variância

<i>k</i>	Classe	$f(x_k)$
1	1,5 – 3,0	1
2	3,0 – 4,5	3
3	4,5 – 6,0	4
4	6,0 – 7,5	2
		10

De forma equivalente ao problema anterior, descrevemos a média amostral a partir de:

$$\bar{x} = \frac{\sum_{k=1}^m \bar{x}_k \cdot f(x_k)}{n}$$

E utilizamos a Tabela 5 para facilitar seu cálculo.

Tabela 5 – Tabela de auxílio para o cálculo da média

<i>k</i>	Classe	$f(x_k)$	$\bar{x}_k$	$\bar{x}_k \cdot f(x_k)$
1	1,5 – 3,0	1	2,25	2,25
2	3,0 – 4,5	3	3,75	11,25
3	4,5 – 6,0	4	5,25	21,00
4	6,0 – 7,5	2	6,75	13,50
		10		48,00

Assim,

$$\bar{x} = \frac{\sum_{k=1}^m \bar{x}_k \cdot f(x_k)}{n} = \frac{48,00}{10} = 4,8$$

E podemos estender na Tabela 6, apresentando o cálculo da variância.



Tabela 6 – Tabela de auxílio para o cálculo da variância

k	Classe	$f(x_k)$	$\bar{x}_k$	$\bar{x}_k \cdot f(x_k)$	$\bar{x}_k - \bar{x}$	$(\bar{x}_k - \bar{x})^2$	$(\bar{x}_k - \bar{x})^2 \cdot f(x_k)$
1	1,5 – 3,0	1	2,25	2,25	–2,55	6,50	6,50
2	3,0 – 4,5	3	3,75	11,25	–1,05	1,10	3,30
3	4,5 – 6,0	4	5,25	21,00	0,45	0,20	0,80
4	6,0 – 7,5	2	6,75	13,50	1,95	3,80	7,60
		10		48,00			18,20

Assim,

$$s^2 = \frac{\sum_{k=1}^m [(\bar{x}_k - \bar{x})^2 \cdot f(x_k)]}{n - 1} = \frac{18,20}{10 - 1} = 2,0$$

$$s = \sqrt{s^2} = \sqrt{2,0} = 1,4$$

TEMA 2 – USO DO DESVIO PADRÃO E COEFICIENTE DE VARIAÇÃO

Geralmente, quando tratamos de dados estocásticos, ou seja, aleatórios, não conseguimos dizer exatamente, i.e., pontualmente, o valor de uma determinada variável. Então, elaboramos um intervalo que diz a probabilidade de determinado dado pertencer a ele. Vejamos como realizar esse cálculo.

2.1 Cálculo da porcentagem de dados em um intervalo

Para isso, suponha os dados descritos na Tabela 7.

Tabela 7 – Exemplo de dados contínuos descritos em classes

k	Classe	$f(x_k)$	$F(x_k)$
1	1,0 – 2,0	1	1
2	2,0 – 3,0	5	6
3	3,0 – 4,0	12	18
4	4,0 – 5,0	18	36
5	5,0 – 6,0	11	47
6	6,0 – 7,0	7	54
7	7,0 – 8,0	3	57
Σ		57	



Podemos calcular, pelo método da seção anterior, a média e o desvio padrão. Nesse caso, encontraríamos $\bar{x} = 4,7$ e $s = 1,9$.

Alguém poderia estar interessado em saber a porcentagem de dados pertencentes ao intervalo $(\bar{x} \pm s)$, ou seja, quantos dados pertencem ao intervalo $(4,7 \pm 1,9)$ definido, portanto, como $[2,8; 6,6]$. Para isso, é necessário relembrar os conceitos de percentil, os quais dividem o intervalo em 100 partes iguais. Sua expressão é dada por:

$$P_p = x_{k(inf)} + \frac{\left[\frac{p \cdot n}{100} - F(x_{k-1}) \right] \cdot (x_{k(sup)} - x_{k(inf)})}{F(x_k) - F(x_{k-1})}$$

Assim, devemos determinar, inicialmente, quantos dados estão abaixo de 2,8, o qual representa o limite inferior do intervalo. Nesse caso, temos:

$$2,8 = 2,0 + \frac{\left[\frac{p \cdot 57}{100} - 1 \right] \cdot (3,0 - 2,0)}{6 - 1}$$

$$p = 8,8$$

Na sequência, devemos determinar quantos dados estão abaixo de 6,6, o qual representa o limite superior do intervalo. Nesse caso, temos:

$$6,6 = 6,0 + \frac{\left[\frac{p \cdot 57}{100} - 47 \right] \cdot (7,0 - 6,0)}{54 - 47}$$

$$p = 89,8$$

Assim, podemos determinar a quantidade de dados que estão no intervalo $[2,8; 6,6]$, chegando em:

$$89,8 - 8,8 = 81\%$$

Poderíamos, também, estar interessados em determinar a quantidade de dados que estão fora de determinado intervalo. Por exemplo, poderíamos descobrir a quantidade de dados fora do intervalo $(\bar{x} \pm 2s)$, i.e., $(4,7 \pm 3,8) = [0,9; 8,5]$. Assim, vejamos a quantidade de dados que estão abaixo de 0,9. Entretanto, quando observamos a Tabela 7 verificamos que não existe nenhum dado abaixo desse limite. Na sequência, devemos encontrar a quantidade de dados que estão abaixo do limite superior. Como 8,5 é maior que o limite da



última classe, verificamos que 100% dos dados estão abaixo de 8,5 e, portanto, a porcentagem de dados que está fora do intervalo $[0,9; 8,5]$ é 0%.

2.2 Coeficiente de variação

Para a comparação de algumas distribuições, não é interessante realizar uma comparação direta, devido à magnitude que alguns dados possuem. Isso pode ser visto, por exemplo, por alguém interessado em pesquisar sobre os gastos de combustível de um automóvel e uma motocicleta que possuem a mesma rota mensal para os primeiros sete meses do ano. Assim, obtém os seguintes dados:

- Automóvel – 750,00 – 800,00 – 790,00 – 810,00 – 820,00 – 760,00 – 780,00
- Motocicleta – 50,00 – 45,00 – 55,00 – 43,00 – 52,00 – 45,00 – 54,00

Quando analisamos a média de combustível gasto, encontramos:

$$\bar{x}_{auto} = 787,14$$

$$s_{auto} = 25,63$$

$$\bar{x}_{moto} = 49,14$$

$$s_{moto} = 4,81$$

Entretanto, estamos interessados em discutir sobre a dispersão nos preços dos combustíveis para cada modal, mas, ao analisar vemos que $s_{auto} > s_{moto}$. Essa informação, a princípio, não nos diz muito sobre a dispersão, visto que o consumo do automóvel é maior que da motocicleta. Então, para realizar de forma adequada a comparação acerca da dispersão, utilizamos o coeficiente de variação, representado por cv e dado por:

$$cv = \frac{\sigma}{\mu}$$

$$cv = \frac{s}{\bar{x}}$$



Assim, vejamos os valores de cv para a motocicleta e o automóvel:

$$cv_{auto} = \frac{25,63}{787,14} = 0,033 = 3,3\%$$

$$cv_{moto} = \frac{4,81}{49,14} = 0,098 = 9,8\%$$

Note que os preços de combustíveis do automóvel são mais estáveis do que o da motocicleta, i.e., possuem uma dispersão menor.

TEMA 3 – MEDIDAS DE ASSIMETRIA

Quando estamos tratando de uma distribuição simétrica podemos descrever suas características a partir de medidas próprias de assimetria. Vejamos quais são elas.

3.1 Distribuição de frequência simétrica

Para termos uma distribuição simétrica, é necessário que sua média, mediana e moda sejam iguais.

3.2 Distribuição de frequência assimétrica

Não sendo simétrica, a distribuição possui uma assimetria. Essa pode ser à esquerda ou à direita, i.e., quando sua cauda estiver do lado esquerdo do gráfico ou quando estiver do lado direito, respectivamente.

Note que quanto mais os dados forem assimétricos, ou seja, quanto maior for a extensão da cauda da distribuição, maior será a distância da média em relação à moda e a mediana.

3.3 Medidas de assimetria

Com essa discussão, podemos entender por que a assimetria é medida por um coeficiente que depende da média, da moda e do desvio padrão ou da média, da mediana e do desvio padrão. A ele damos o nome de coeficiente de Pearson, A_p :



$$A_p = \frac{\text{média} - \text{moda}}{\text{desvio padrão}}$$
$$A_p = \frac{3 \cdot (\text{média} - \text{mediana})}{\text{desvio padrão}}$$

A partir da análise de A_p , podemos chegar a algumas conclusões acerca da assimetria. Sendo $A_p < 0$, trata-se de uma distribuição assimétrica negativa. Sendo $A_p > 0$, trata-se de uma distribuição assimétrica positiva. Caso contrário, i.e., $A_p = 0$, trata-se de uma distribuição simétrica.

Alguns autores irão considerar simétrico para um intervalo maior de A_p , visto que, estatisticamente, é quase impossível que $A_p = 0$. Assim, podem considerar, por exemplo, $|A_p| < 0,15$ como uma distribuição simétrica, $0,15 \leq |A_p| \leq 1,0$ como uma distribuição assimétrica moderada e $|A_p| \geq 1,0$ como uma distribuição assimétrica forte.


TEMA 4 – MEDIDAS DE CURTOSE

Na seção anterior, vimos que uma determinada distribuição pode ser simétrica ou não, indicando, assim, o comportamento de sua cauda. Agora, vejamos a característica de *curtose* indicando a forma que a curva possui em relação ao achatamento.

4.1 Distribuição normal

A medida de curtose é realizada em comparação com os parâmetros de uma distribuição simétrica conhecida como distribuição normal, como a apresentada na Figura 1.

Figura 1 – Exemplo de distribuição normal





4.2 Tipos de distribuição em relação à curtose

Assim, definimos a curtose em relação à distribuição normal. Se os dados estiverem alinhados de acordo com ela, dizemos que se trata de uma distribuição *mesocúrtica*. Quando a distribuição é mais achatada que a normal, se trata de uma distribuição *platicúrtica*. Enfim, quando a distribuição é mais pontiaguda que a normal, se trata de uma distribuição *leptocúrtica*.

Para evitar uma análise visual, podemos calcular a medida de curtose k a partir do primeiro quartil, Q_1 , do terceiro quartil, Q_3 , do décimo percentil, P_{10} e do nonagésimo percentil, P_{90} :

$$k = \frac{\frac{Q_3 - Q_1}{2}}{P_{90} - P_{10}}$$

Como fazemos a comparação com a distribuição normal, podemos calcular, para esta os valores de Q_1, Q_3, P_{10} e P_{90} :

$$Q_1 = -0,675$$

$$Q_3 = 0,675$$

$$P_{10} = -1,282$$

$$P_{90} = 1,282$$

E, portanto, no caso de uma distribuição dessas, encontramos

$$k = \frac{\frac{0,675 + 0,675}{2}}{1,282 + 1,282} = 0,263$$

Que representa a distribuição mesocúrtica. Quando $k < 0,263$ se trata da distribuição leptocúrtica e, caso contrário, quando $k > 0,263$ se trata da distribuição platicúrtica.

Alguns autores utilizam, para o cálculo de k , a expressão:

$$k = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})^4}{n}}{s^4}$$



TEMA 5 – EXEMPLO

Vejamos como determinar o tipo de distribuição que determinado conjunto de dados possui neste exemplo a seguir.

Para isso, iremos considerar o número de 100 camisetas vendidas em uma determinada loja. Assim, considere os seguintes dados, apresentados na Tabela 8.

Tabela 8 – Frequência de quantidade de camisetas vendidas por tamanho

Número das Camisetas	Frequência
25,0 – 28,0	2
28,0 – 31,0	9
31,0 – 34,0	17
34,0 – 37,0	35
37,0 – 40,0	20
40,0 – 43,0	10
43,0 – 46,0	7

Vejamos como classificar a assimetria e a curtose desse conjunto de dados. Para isso, é importante calcularmos, inicialmente, a média dos dados. Assim, expandimos a Tabela 8 na Tabela 9, a seguir.

Tabela 9 – Tabela de auxílio para o cálculo da média

k	Classes	$f(x_k)$	$F(x_k)$	$\bar{x}_k$	$\bar{x} \cdot f(x_k)$
1	25,0 – 28,0	2	2	26,5	53
2	28,0 – 31,0	9	11	29,5	265,5
3	31,0 – 34,0	17	28	32,5	552,5
4	34,0 – 37,0	35	63	35,5	1242,5
5	37,0 – 40,0	20	83	38,5	770
6	40,0 – 43,0	10	93	41,5	415
7	43,0 – 46,0	7	100	44,5	311,5
Σ		100			3610



Assim,

$$\bar{x} = \frac{3610}{100} = 36,1$$

Para encontrar a moda, verificamos que a classe modal, aquela de maior frequência, é a quarta classe. Assim, a moda será $\bar{x}_4 = 35,5$.

Para o cálculo da mediana, percebemos que, observando $F(x_k)$ que pertence à quarta classe também. Assim, calculamos a partir de:

$$\text{mediana} = 34,0 + \frac{\left(\frac{100}{2} - 28\right) \cdot (37,0 - 34,0)}{63 - 28} = 35,9$$

Para calcularmos a variância, ampliamos a Tabela 9 na Tabela 10.

Tabela 10 – Tabela de auxílio para o cálculo da variância

<i>k</i>	Classes	$f(x_k)$	$F(x_k)$	$\bar{x}_k$	$\bar{x} \cdot f(x_k)$	$\bar{x}_k - \bar{x}$	$(\bar{x}_k - \bar{x})^2$	$(\bar{x}_k - \bar{x})^2 \cdot f(x_k)$
1	25,0 └ 28,0	2	2	26,5	53	−9,6	92,16	184,32
2	28,0 └ 31,0	9	11	29,5	265,5	−6,6	43,56	392,04
3	31,0 └ 34,0	17	28	32,5	552,5	−3,6	12,96	220,32
4	34,0 └ 37,0	35	63	35,5	1242,5	−0,6	0,36	12,60
5	37,0 └ 40,0	20	83	38,5	770	2,4	5,76	115,20
6	40,0 └ 43,0	10	93	41,5	415	5,4	29,16	291,60
7	43,0 └ 46,0	7	100	44,5	311,5	8,4	70,56	493,92
Σ		100			3610			1.710,00



Assim, podemos escrever:

$$s^2 = \frac{1.710,00}{100 - 1} = 17,27$$

Para o valor da variância e

$$s = \sqrt{17,27} = 4,2$$

Para o valor do desvio padrão.

Finalmente, podemos tirar uma primeira conclusão sobre o tipo de distribuição. Para isso, calculamos:

$$A_p = \frac{36,1 - 35,5}{4,2} = 0,14$$

Indicando uma distribuição simétrica. Em relação à curtose, devemos encontrar, inicialmente, os quartis e na sequência os percentis:

$$Q_1 = 31,0 + \frac{\left(\frac{100}{4} - 11\right) \cdot (34,0 - 31,0)}{28 - 11} = 33,5$$

$$Q_3 = 37,0 + \frac{\left(\frac{3 \cdot 100}{4} - 63\right) \cdot (40,0 - 37,0)}{83 - 63} = 38,8$$

$$P_{10} = 28,0 + \frac{\left(\frac{10 \cdot 100}{100} - 2\right) \cdot (31,0 - 28,0)}{11 - 2} = 30,7$$

$$P_{90} = 40,0 + \frac{\left(\frac{90 \cdot 100}{100} - 83\right) \cdot (43,0 - 40,0)}{93 - 83} = 42,1$$

Finalmente,

$$k = \frac{\frac{38,8 - 33,5}{2}}{42,1 - 30,7} = 0,232$$

Indicando uma distribuição ligeiramente leptocúrtica.

FINALIZANDO

Verificamos quais os principais fundamentos necessários para analisar determinado conjunto de dados.