



DEEP LEARNING

AULA 5



Prof. Elton Masaharu Sato

CONVERSA INICIAL

Imagine um mundo onde robôs aprendem sozinhos a realizar tarefas complexas, sistemas de recomendação entendem AS suas preferências com maestria, e carros autônomos tomam decisões mais inteligentes do que humanos ao volante. Esse cenário pode parecer uma história de ficção científica, mas é a realidade em constante evolução no campo da inteligência artificial, graças ao poder do aprendizado por reforço, ou Reinforcement Learning (RL).

O aprendizado por reforço é uma área fascinante da inteligência artificial, inspirada pela forma como humanos e animais aprendem a partir de suas experiências e interações com o ambiente. No RL, um agente, como um robô ou um algoritmo, aprende a tomar decisões otimizadas e a alcançar objetivos por meio de tentativa e erro, sendo recompensado por ações bem-sucedidas e penalizado por erros.

TEMA 1 – INTRODUÇÃO AO REINFORCEMENT LEARNING



Crédito: DG-Studio/Shutterstock.

1.1 O que é Reinforcement Learning (RL)

Reinforcement Learning (RL) é uma técnica de aprendizado de máquina que permite aos agentes aprender a tomar ações em um ambiente para alcançar uma determinada meta. O agente é incentivado a fazer escolhas por meio de recompensas e punições que são dadas a ele ao longo do tempo. O objetivo é



encontrar a melhor combinação de ações que resulte na maior recompensa possível.

O RL é diferente de outras técnicas de aprendizado de máquina, como a aprendizagem supervisionada, na medida em que o agente é responsável por decidir as ações que vão ser tomadas, em vez de ser guiado por dados previamente rotulados. Além disso, o agente é incentivado a explorar diferentes ações e ambientes, a fim de descobrir a combinação que resulta na maior recompensa.

Dessa forma, o RL é uma técnica de aprendizado de máquina que permite aos agentes aprender por meio de tentativa e erro, a fim de encontrar a melhor combinação de ações para alcançar a sua meta.

1.2 Aplicações de Reinforcement learning


As aplicações do Reinforcement Learning (RL) são vastas e abrangentes, em muitas áreas diferentes. Alguns dos campos mais comuns onde o RL é aplicado incluem jogos, robótica, sistemas de recomendação e controle de sistemas:

- Jogos: o RL tem sido aplicado com sucesso em jogos, como xadrez, damas, Go, entre outros. Em jogos, o agente de RL aprende a tomar ações baseadas nas recompensas e punições que recebe ao longo do jogo. Um exemplo bem conhecido é o AlphaGo, desenvolvido pela DeepMind, que venceu o campeão mundial de Go em 2016. Um documentário completo pode ser encontrado no canal oficial do DeepMind: <<https://www.youtube.com/watch?v=WXuK6gekU1Y>>.



Crédito: maxuser/Shutterstock.

- Robótica: o RL também é amplamente utilizado em robótica, área que demanda que os robôs aprendam a tomar ações com base em seu ambiente e no feedback que recebem. Por exemplo, os robôs podem aprender a equilibrar objetos, navegar em ambientes desconhecidos e realizar tarefas complexas.



Crédito: ktsdesign/Shutterstock.

- Sistemas de recomendação: o RL também é aplicado em sistemas de recomendação, com o objetivo de recomendar itens aos usuários, com base em seu comportamento anterior e em recompensas que eles recebem. Por exemplo, um sistema de recomendação de música pode aprender a recomendar músicas aos usuários a partir das músicas que eles escutam e da satisfação que sentem com as recomendações.
- Controle de sistemas: o RL também é amplamente utilizado em controle de sistemas, com o objetivo de controlar sistemas complexos, como sistemas de energia e sistemas de transporte. O RL é capaz de aprender a tomar ações com base em recompensas e punições que recebe ao longo do tempo, o que permite aos sistemas operar de forma mais eficiente e eficaz.



Crédito: Cinemanikor/Shutterstock.

1.3 Elementos do RL

Os elementos-chave do RL são: ambiente, agente e recompensa. Cada um desses elementos é fundamental para compreender como o RL funciona e como os agentes aprendem a tomar ações.

- Ambiente: lugar onde o agente age e onde as ações são tomadas. O ambiente pode ser qualquer coisa, desde um jogo até um sistema físico complexo. O ambiente fornece informações ao agente sobre a sua situação atual e sobre as ações que podem ser tomadas.
- Agente: ator responsável por tomar as ações no ambiente. O agente é programado para aprender a tomar ações com base nas recompensas e punições que recebe ao longo do tempo. O agente é capaz de aprender por meio de tentativa e erro, tornando-se cada vez mais hábil em tomar ações eficazes.
- Recompensa: sinal que o agente recebe para indicar se a sua ação foi boa ou não. A recompensa pode ser positiva ou negativa. Ela é usada pelo agente para aprender a tomar ações mais eficazes. Por exemplo, em um jogo de xadrez, o agente pode receber uma recompensa positiva por



fazer uma jogada bem-sucedida e uma recompensa negativa por fazer uma jogada que não é bem-sucedida.

Podemos utilizar o exemplo da própria natureza, pois acredita-se que o RL explica uma das formas pelas quais os animais aprendem alguns comportamentos.



Crédito: Ondrej Prosicky/Shutterstock.

Por exemplo, a nossa raposa fará o papel de “agente”. Ela acorda todo dia e deve escolher o que deve caçar para se alimentar e sobreviver. Vamos supor que, no ambiente em que está inserida, ela tem duas opções. Ela pode caçar peixes, com altas chances de sucesso, mas o peixe oferece pouca nutrição para a raposa, saciando-a por pouco tempo. Essa é a sua recompensa quando realiza a ação.



Crédito: Zdenek Machacek/Shutterstock.

Ela também poderá caçar lebres, ainda que tenha baixas chances de sucesso na caçada. Entretanto, a lebre a alimenta por muito mais tempo, e a raposa fica saciada por um longo período de tempo. Essa recompensa é bem maior do que a recompensa de caçar peixes.



Crédito: WildMedia/Shutterstock.



Levando em consideração que a raposa pode sobreviver alguns dias alimentando-se apenas de pequenos frutos e vegetação, o ideal para uma raposa nesse cenário seria que ela caçasse lebres. Caso falhe na tarefa muitas vezes, ela poderá caçar peixes para sobreviver, intercalando ambos os comportamentos. Se a raposa consegue caçar uma lebre, ela fica satisfeita por alguns dias, e assim poderá descansar depois de ter passado vários dias caçando.

Como cada raposa na natureza terá resultados diferentes em suas caçadas, enquanto é treinada, se uma raposa tiver sorte em caçar lebres, ela pode ter uma propensão maior em caçar lebres, mesmo quando o melhor cenário seja caçar peixes.

TEMA 2 – TEORIA BÁSICA DO REINFORCEMENT LEARNING

2.1 Processo decisório de Markov (MDP)


O processo decisório de Markov (Markov Decision Process – MDP) é um modelo matemático que descreve o Reinforcement Learning (RL) como um processo de tomada de decisão. O MDP é composto por um conjunto de estados, ações e recompensas, que são os três elementos-chave do RL.

- **Estados:** o MDP define o ambiente como um conjunto de estados. Cada estado representa a situação atual do ambiente. Por exemplo, em um jogo de xadrez, cada estado pode representar a configuração atual das peças no tabuleiro.
- **Ações:** o MDP também define as ações disponíveis para o agente em cada estado. Por exemplo, em um jogo de xadrez, as ações podem ser mover uma peça para uma determinada posição.
- **Recompensas:** o MDP define as recompensas associadas a cada ação. As recompensas são usadas pelo agente para o aprendizado de ações mais eficazes. Por exemplo, em um jogo de xadrez, o agente pode receber uma recompensa positiva por fazer uma jogada bem-sucedida e uma recompensa negativa por fazer uma jogada que não é bem-sucedida.



Crédito: Sorapop Udomsri/Shutterstock.

O MDP é usado para descrever o RL como um processo de tomada de decisão. O objetivo do agente é encontrar a melhor política, ou seja, a combinação de regras que resulta na maior recompensa possível. O MDP fornece uma maneira de formalizar esse problema, sendo amplamente utilizado para desenvolver e avaliar algoritmos de RL.





Um exemplo prático do dia a dia, que pode ser modelado como um MDP, é a decisão de escolha de rota para chegar ao trabalho. O ambiente é composto pelas diferentes opções de rota. O agente é o motorista, que precisa decidir a rota de escolha. As ações são as escolhas de rota e as recompensas são os tempos de viagem de cada rota.

O motorista pode aprender a escolher a rota mais rápida por meio de experimentação, tomando diferentes rotas e observando os tempos de viagem associados. A cada viagem, o motorista recebe uma recompensa com base no tempo de viagem. Com o tempo, aprende a escolher a rota que resulta no menor tempo de viagem.

Esse exemplo pode ser modelado como um MDP: o ambiente é composto pelas diferentes opções de rota, o agente é o motorista e as ações são as escolhas de rota. As recompensas são os tempos de viagem associados a cada rota e o objetivo é encontrar a rota que resulta no menor tempo de viagem. Ao longo do tempo, o motorista aprende a tomar ações com base nas recompensas que recebe, tornando-se cada vez mais hábil em escolher a rota mais rápida para chegar ao trabalho.

2.2 Políticas, estados e ações

As seções de políticas e valores de estado/ação são duas áreas importantes do RL. Juntas, descrevem como o agente aprende a tomar ações no ambiente para alcançar a maior recompensa possível.

- Políticas: uma política é uma regra que descreve como o agente deve tomar ações em cada estado. Em outras palavras, uma política é uma função que dá ao agente a próxima ação que deve ser tomada, a partir da sua situação atual. O objetivo do RL é encontrar a política ótima, ou seja, a política que resulta na maior recompensa possível.
- Valores de estado/ação: números que descrevem o valor esperado de uma ação em um determinado estado. Em outras palavras, os valores de estado/ação descrevem quanto o agente espera ganhar ao tomar uma determinada ação em um determinado estado. O objetivo do RL é encontrar valores de estado/ação ótimos, ou seja, valores que resultam na maior recompensa possível.



Ambos as seções de políticas e valores de estado/ação são importantes para o RL, pois juntas descrevem como o agente aprende a tomar ações eficazes no ambiente. Ao aprender a política ótima e os valores de estado/ação ótimos, o agente é capaz de alcançar resultados surpreendentes em muitas aplicações diferentes.

TEMA 3 – TÉCNICAS DE APRENDIZADO DE REINFORCEMENT LEARNING

3.1 Aprendizagem por valor

A aprendizagem por valor é uma técnica de Reinforcement Learning (RL) que permite aos agentes aprender a tomar ações eficazes no ambiente, com base em valores de estado/ação. A aprendizagem por valor se baseia na ideia de que o agente pode aprender a tomar ações que resultam em maior recompensa ao longo do tempo.

- Valores de estado: são números que descrevem o valor esperado por estar em um determinado estado. Em outras palavras, os valores de estado descrevem quanto o agente espera ganhar quando está em um determinado estado. O objetivo da aprendizagem por valor é encontrar os valores de estado ótimos, ou seja, os valores que resultam na maior recompensa possível.
- Valores de estado/ação: números que descrevem o valor esperado de uma ação em um determinado estado. Em outras palavras, os valores de estado/ação descrevem quanto o agente espera ganhar ao tomar uma determinada ação em um determinado estado. O objetivo da aprendizagem por valor é encontrar os valores de estado/ação ótimos, ou seja, os valores que resultam na maior recompensa possível.

A aprendizagem por valor se baseia no conceito de que o agente pode aprender a tomar ações eficazes a partir dos valores de estado/ação. A cada ação, o agente atualiza os valores de estado/ação com base na recompensa recebida, tornando-se cada vez mais hábil em tomar ações eficazes.

Em resumo, a aprendizagem por valor é uma técnica de RL que permite aos agentes aprender a tomar ações eficazes no ambiente, com base em valores de estado/ação. A aprendizagem por valor se baseia na ideia de que o agente pode aprender a tomar ações que tragam maior recompensa, ao longo do tempo,



tornando-se cada vez mais hábil em tomar ações eficazes. Ao encontrar os valores de estado/ação ótimos, o agente é capaz de alcançar resultados surpreendentes em muitas aplicações diferentes.



Crédito: Patrick Hatt/Shutterstock.

Para modelar uma Inteligência Artificial com RL para jogar Banco Imobiliário, podemos jogar todas as regras dentro do sistema, pois as probabilidades são conhecidas. Podemos não saber qual número sairá nos dados em cada momento, mas sabemos quais são as chances de cada resultado possível nos dados (considerando dados honestos em que cada face tem as exatas mesmas chances de serem roladas).

A partir dessa política e de estados possíveis de jogo, a inteligência artificial só precisaria iterar pelo sistema até encontrar o melhor caminho possível para chegar na melhor recompensa. A recompensa poderia ser modelada de diversas formas, como a posição do jogador no tabuleiro, a quantidade de dinheiro que o jogador tem, as propriedades que o jogador tem, se há combos de propriedades do jogador etc.



3.2 Aprendizagem por política

A aprendizagem por política é uma técnica de RL que permite aos agentes aprender a tomar ações eficazes no ambiente, com base nas políticas. A aprendizagem por política se baseia na ideia de que o agente pode aprender a tomar ações que tragam maior recompensa ao longo do tempo.

- Políticas: uma política é uma regra que descreve como o agente deve tomar ações em cada estado. Em outras palavras, uma política é uma função que dá ao agente a próxima ação a ser tomada, dada a situação atual. O objetivo da aprendizagem por política é encontrar a política ótima, ou seja, a política que resulta na maior recompensa possível.
- Algoritmos de aprendizagem por política: existem vários algoritmos de aprendizagem por política, incluindo o algoritmo de Policy Gradient e o algoritmo Proximal Policy Optimization (PPO). Eles usam diferentes técnicas para aprender a política ótima, mas todos se baseiam na ideia de que o agente pode aprender a tomar ações eficazes com base em políticas.

A aprendizagem por política é baseada no conceito de que o agente pode aprender a tomar ações eficazes a partir de políticas. A cada ação, o agente atualiza a sua política com base na recompensa recebida, tornando-se cada vez mais hábil em tomar ações eficazes.

Em um jogo de plataforma como Mario, a dificuldade é justamente encontrar as probabilidades e as recompensas de uma ação. É fácil descobrir quais são os valores, pois podemos considerar fatores como moedas, score, tempo restante e o quanto o Mario se moveu na tela para a direita. Porém, mapear tudo isso para conseguir a política é a parte difícil. Portanto, para esse jogo, a abordagem ideal, entre aprendizado por valor ou aprendizado por política, seria o aprendizado por política.



Crédito: Mehaniq/Shutterstock.

TEMA 4 – MÉTODOS DE REINFORCEMENT LEARNING

4.1 Método de Monte Carlo

O método Monte Carlo é uma técnica de Reinforcement Learning (RL) que permite aos agentes aprender a partir da experiência. Em vez de seguir uma política determinística, o método Monte Carlo permite ao agente experimentar diferentes ações e aprender a partir da recompensa resultante.

- Simulação de episódios: no método Monte Carlo, o agente simula vários episódios completos do ambiente, ou seja, ele joga o jogo várias vezes do início até o fim. A cada episódio, o agente toma ações aleatórias e registra a recompensa resultante.
- Cálculo de valores de estado/ação: depois de simular vários episódios, o agente usa as informações registradas para calcular os valores de estado/ação. Os valores de estado/ação são números que descrevem quanto o agente espera ganhar ao tomar uma determinada ação em um determinado estado. O objetivo do método Monte Carlo é encontrar os valores de estado/ação ótimos, ou seja, os valores que resultam na maior recompensa possível.



- Aprendizagem por valor: depois de calcular os valores de estado/ação, o agente usa essas informações para atualizar a sua política. A política é uma regra que descreve como o agente deve tomar ações em cada estado. O objetivo da política é escolher a ação que resulta na maior recompensa, de acordo com os valores de estado/ação.

4.2 Método de diferença temporal

O método de diferença temporal é uma técnica de RL que permite aos agentes aprender a partir de sua experiência no ambiente. O objetivo do método de diferença temporal é encontrar a política ótima, ou seja, a política que resulta na maior recompensa possível.

- Cálculo de valores de estado/ação: no método de diferença temporal, o agente usa uma equação para calcular os valores de estado/ação. Os valores de estado/ação são números que descrevem quanto o agente espera ganhar ao tomar uma determinada ação em um determinado estado. A equação usada para calcular os valores de estado/ação é conhecida como equação de Bellman.
- Atualização dos valores de estado/ação: a cada ação, o agente atualiza os valores de estado/ação com base na recompensa recebida e nos valores de estado/ação dos estados seguintes. Essa atualização permite ao agente aprender a partir de sua experiência no ambiente e se tornar cada vez mais hábil em tomar ações eficazes.
- Aprendizagem por valor: depois de calcular os valores de estado/ação, o agente usa essas informações para atualizar a sua política. A política é uma regra que descreve como o agente deve tomar ações em cada estado. O objetivo da política é escolher a ação que resulta na maior recompensa, de acordo com os valores de estado/ação.

Em resumo, o método de diferença temporal é uma técnica de RL que permite aos agentes aprender a partir de sua experiência no ambiente. O método de diferença temporal usa uma equação para calcular os valores de estado/ação e atualiza esses valores a cada ação. Depois de calcular os valores de estado/ação, o agente usa as informações para atualizar a sua política. Ao longo do tempo, o agente torna-se cada vez mais hábil em tomar ações eficazes, o que resulta em melhor desempenho. O método de diferença temporal é uma técnica



poderosa que tem sido usada com sucesso em muitas aplicações diferentes de RL, incluindo jogos eletrônicos e outros ambientes controlados.

TEMA 5 – DESAFIOS E LIMITAÇÕES DO REINFORCEMENT LEARNING

O Reinforcement Learning (RL) é uma área da inteligência artificial que permite a construção de agentes capazes de aprender a partir de sua interação com o ambiente. Embora o RL ofereça muitas possibilidades em termos de aplicações práticas, ele também apresenta desafios computacionais significativos que precisam ser abordados para que seja possível construir agentes eficazes e escaláveis.

- **Dificuldade em modelar o ambiente:** um dos principais desafios na implementação de RL é modelar o ambiente de forma precisa. Muitos ambientes são incertos, complexos e dinâmicos, o que torna difícil prever a recompensa resultante de uma determinada ação. Além disso, muitos ambientes são grandes e apresentam muitos estados, o que pode dificultar a representação do ambiente de forma completa. Por exemplo, no xadrez, é muito difícil avaliar se um posicionamento das peças é melhor do que outro. Se levar em consideração apenas o valor das peças, a IA irá cair em todas as armadilhas do oponente.
- **Escalabilidade:** outro importante desafio no RL é a escalabilidade. Muitos ambientes são muito grandes e complexos para que sejam explorados completamente. Além disso, a aprendizagem por meio de simulações pode ser muito lenta, especialmente em ambientes grandes e complexos. Por exemplo: ensinar um carro a dirigir em qualquer lugar no mundo
- **Dificuldades para aprender políticas ótimas:** o RL envolve a busca por políticas ótimas, ou seja, políticas que resultem na maior recompensa possível. No entanto, encontrar políticas ótimas pode ser difícil, pois o RL encontra ótimos locais e não procura por todo o espaço de possibilidades. Por exemplo: em ambientes com “atalhos”, o agente pode não aprender o atalho.
- **Recursos computacionais:** o RL envolve a simulação de muitos episódios completos do ambiente, o que pode exigir muito poder de computação. Além disso, a aprendizagem por valor pode exigir muitos cálculos, de



modo que o processo de aprendizagem pode ser lento. Por exemplo: o custo diário do ChatGPT é de aproximadamente 1 milhão de dólares.

- Dificuldade para gerar dados de treinamento: Muitos ambientes de RL são incertos, complexos e dinâmicos, o que torna difícil gerar dados de treinamento precisos. Além disso, muitos ambientes são grandes e apresentam muitos estados, o que pode tornar difícil explorar completamente o ambiente e gerar dados de treinamento suficientes. Isso se deve ao fato de que os agentes devem aprender com base em suas próprias interações com o ambiente, em vez de simplesmente confiar em um conjunto de dados pré-coletado.
- Dificuldade para garantir a convergência: o RL envolve a busca por políticas ótimas, o que pode ser difícil, especialmente quando o ambiente é incerto e complexo. Por exemplo: mercado financeiro.

FINALIZANDO

O Reinforcement Learning (RL) é uma área da inteligência artificial que permite a construção de agentes capazes de aprender a partir de sua interação com o ambiente. Ele se baseia em três elementos-chave: ambiente, agente e recompensa. O RL é implementado por meio de políticas e valores de estado/ação. Existem duas abordagens principais para aprender essas políticas: aprendizagem por valor e aprendizagem por política.

O RL tem ampla aplicação em jogos. Existem dois métodos principais de aprendizagem no RL: o de Monte Carlo e o método de diferença temporal. Além disso, o RL apresenta desafios computacionais significativos, incluindo a dificuldade para modelar o ambiente de forma precisa, a escalabilidade, a dificuldade de aprender políticas ótimas e a computação de alta performance. Finalmente, a definição da recompensa é um aspecto crítico no RL, apresentando dificuldades como a complexidade da tarefa, a ambiguidade na recompensa, o conflito de interesses, a falta de informação e as mudanças no ambiente.