



INTELIGÊNCIA ARTIFICIAL APLICADA - MACHINE LEARNING

AULA 1



Prof. Antonio Willian Sousa



CONVERSA INICIAL

Olá! Seja bem-vindo(a) a esta aula! Nela, apresentaremos os conceitos básicos da área, seus fundamentos, sua diferenciação e uso em relação à Ciência de Dados. Apresentaremos também as definições de dado, informação e atributo. Explicaremos a importância dos atributos e dos diferentes métodos de aprendizagem da Aprendizagem de Máquina e para encerrar apresentaremos algumas das ferramentas que você precisa ter no seu kit de ferramentas para construir e usar modelos de aprendizagem.

Se este for o seu primeiro contato com esta área e alguns dos termos e expressões utilizadas causarem estranheza ou espanto, não se preocupe que os conceitos serão apresentados de forma estrutural, do mais simples para o mais complexo, permitindo um entendimento holístico da área e de seus métodos.

TEMA 1 – CONCEITOS BÁSICOS

Intuitivamente, todos nós temos um conceito implícito do que é inteligência e da sua importância, pois a nossa capacidade de raciocínio é o que nos distingue dos demais seres vivos e tornou possível ao homem moldar a natureza e seus recursos em seu benefício. A busca por um entendimento mais amplo da nossa capacidade de raciocínio e da nossa diferenciação em relação aos demais seres vivos sempre nos intrigou e, ao longo do tempo, muitos estudiosos buscaram compreender melhor o pensamento e o raciocínio humano.

A área da Inteligência Artificial (IA) busca algo além de apenas entendimento dos mecanismos responsáveis pelo raciocínio do ser humano. Ela busca reproduzir, simular ou imitar a maneira do homem capturar, codificar, decodificar e processar as informações do mundo à sua volta, por meio da construção de entidades, que possam ser consideradas inteligentes.

1.1 A inteligência artificial

A Inteligência Artificial é uma área de estudo relativamente nova, com os seus preceitos tendo sido definidos por volta da década de 1950, antes mesmo de os computadores iniciarem o seu desenvolvimento rumo à capacidade de processamento e armazenamento que presenciamos nos dias atuais. Como veremos ao longo da aula, alguns conceitos somente se tornarem possíveis de



execução quando os computadores e os demais dispositivos apresentaram condições de manipular dados em grandes volumes, algo que nós conseguimos fazer naturalmente, mesmo sem nos darmos conta que somos usuários de uma poderosa máquina de processamento e armazenamento dos mais diversos tipos de informação: o nosso cérebro.

Já na década de 1950, o cientista Alan Turing, considerado um dos pais da IA, projetou um teste – Teste de Turing – que ainda permanece alvo de estudos e investigação nos dias atuais. Conhecer este teste é importante, pois por meio dele podemos ter uma noção mais clara do desenvolvimento da área e de subáreas que se estruturam dentro do campo da IA. O Teste de Turing consiste numa situação hipotética em que um entrevistador interage com uma entidade, sem visualizá-la e suas perguntas são passadas por escrito para esta entidade. Ao receber as respostas se o entrevistador não conseguir distinguir se estas respostas foram produzidas por um humano ou por um computador, o computador, quem de fato recebeu e respondeu aos questionamentos, passaria no teste.

De acordo com Russel e Norvig (2013), para um computador ser aprovado no Teste de Turing, ele precisaria atender alguns requisitos e apresentar as seguintes capacidades:

- *capacidade robótica* para manipular objetos físicos e mover-se;
- *visão computacional* para perceber objetos;
- *processamento de linguagem natural* para permitir comunicação com sucesso em uma língua natural;
- *representação de conhecimento* para armazenar conhecimento;
- *raciocínio automatizado* para utilizar o conhecimento armazenado, responder perguntas e chegar a novas conclusões;
- *aprendizado de máquina* como forma de adaptar-se a situações novas, detectar e extrapolar padrões conhecidos.

Aqui vale a pena deixar claro que o objetivo da IA não é reproduzir fielmente a forma do ser humano pensar e processar informação, mas sim obter os mesmos resultados que nós em tarefas diversas. Para os curiosos que quiserem se aventurar nesta outra linha, recomendamos procurar a disciplina de ciência cognitiva. Nos primórdios da IA não havia uma separação clara entre estes campos de estudos. Atualmente, os pesquisadores e autores buscam



tratá-las separadamente, o que não impede que eles auxiliem no seu desenvolvimento mútuo, tendo, na verdade, contribuído para que cada área conquistasse avanços consideráveis.

Com informações do surgimento da Inteligência Artificial e suas subáreas em mãos, fica claro que a Aprendizagem de Máquina é uma de suas abordagens voltadas para o desenvolvimento de programas que possam simular as capacidades humanas, porém essa abordagem se distingue de outras e à medida que ela se expandiu, tornou-se necessário organizar melhor a área como um todo para direcionar os trabalhos, especialmente aqueles voltados para a exploração e descoberta de novos métodos.

1.2 A evolução da área

Apresentaremos a seguir uma evolução da área de IA:

- De 1943 a 1956: pode ser considerado como o período de criação das bases e estabelecimento da área, culminando com o seu nascimento em 1956, com destaque para um seminário ocorrido em Dartmouth naquele mesmo ano, que reuniu pesquisadores da área de teoria de autômatos, redes neurais e estudos da inteligência. Esse encontro explicitou a necessidade de estabelecer a IA como um campo de estudo em separado dos demais.
- De 1956 a 1969: pode ser considerado como o período das grandes expectativas da IA. Houve o estabelecimento da hipótese do sistema de símbolos físicos, que determinaria a condução ao longo dos anos subsequentes em direção ao que hoje conhecemos como IA simbólica. Houve ainda a especificação da linguagem LISP, que por anos foi preponderante na área e, de forma mais tímida que as outras inovações, tivemos a apresentação do trabalho de Frank Rosenblatt (1962) com os perceptrons. Esse trabalho se provaria mais tarde como responsável pelos conceitos e modelos que hoje dominam o campo da aprendizagem de máquina.
- De 1966 a 1973: os avanços na área foram limitados, seja pela capacidade computacional e de armazenamento disponíveis à época, seja pela incapacidade de representação dos problemas e dos dados a eles relacionados, devendo-se também considerar que a baixa



capacidade de representação e a incapacidade de lidar com problemas cuja complexidade escalava de forma exponencial ou combinatória levaram ao encerramento de vários projetos de apoio ao crescimento da área em diversas universidades.

- De 1969 a 1979: nesse período houve um foco maior no conhecimento sobre os problemas a serem resolvidos, o que culminou com a disseminação de programas especialistas compostos por um conjunto de regras (conhecimento do problema). Esses programas ganharam notoriedade a partir do momento que permitiram às empresas a economia de milhares de dólares, provando o valor da IA para a indústria.
- De 1980 a 1994: no início dos anos 1980, nasce a indústria da IA e vários centros de pesquisa que no passado haviam cortado subsídios da área resolvem retomar os investimentos, mas novamente as expectativas foram muito elevadas e a IA passou por um período conhecido como “inverno da IA”. Em 1986, com a reinvenção do algoritmo de retroprogramação, os modelos conexionistas, baseados em neurônios artificiais, voltaram a se destacar como solução de problemas que a IA simbólica não conseguia tratar. Seguindo esse processo, a IA tornou-se uma ciência, com destaque para o uso de métodos matemáticos rigorosos como Modelos Ocultos de Markov para resolução de problemas como reconhecimento de fala, o surgimento da área de mineração de dados e o estabelecimento da aprendizagem bayesiana.
- De 1995 até os dias atuais: os métodos de IA se tornaram mais comuns, fazendo parte de diversas aplicações do dia, especialmente sistemas de buscas na internet, sistemas agregadores de conteúdo e sistemas de recomendação. Com o aumento da capacidade para lidar com grandes volumes de dados, as abordagens de IA se voltaram menos para os algoritmos e mais para os dados e a sua representação, sendo comuns afirmações de que os seus resultados serão tão bons quanto a quantidade de dados que você tiver disponível.



1.3 O que a inteligência artificial pode fazer?

A grande quantidade de áreas nas quais a IA está presente nos dias atuais torna difícil enumerar sua atuação. Essa presença massiva de IA, por vezes, passa despercebida, pois o uso é feito de forma transparente. Dentre as aplicações, podemos destacar:

- Detecção de spam em serviços de e-mail: esse, praticamente, pode ser considerado um problema clássico da IA moderna;
- Identificação e traçado de trajeto para robôs;
- Planejamentos logísticos;
- Jogos de computador, cujos exemplos vão desde a derrota de um campeão de xadrez por um computador, até os atuais personagens autônomos inteligentes dos jogos mais atuais e dos algoritmos que aprendem o seu estilo de jogo e permanecem conduzindo o seu personagem em mundos virtuais enquanto você não está conectado;
- Planejamento autônomo e escalonamento, que vão desde a operação de equipamentos e estruturas tecnológicas a naves espaciais;
- Reconhecimento de voz, com capacidades de identificação e conversão de voz em texto, bem como a identificação biométrica de pessoas pelas características intrínsecas de sua voz;
- Veículos robóticos autoguiados, como aqueles utilizados em explorações espaciais e carros autônomos;
- Tradução automática de textos e voz de uma língua para outra, com precisão equivalente a um tradutor humano como conhecimento nas duas línguas.

Os exemplos citados não esgotam todas as possibilidades do campo de IA, nem tão pouco o que é possível fazer utilizando aprendizagem de máquina. Contudo, fica claro que essa área, além de promissora, vive um momento no qual novas formas de representação, novas arquiteturas e diferentes modelos e algoritmos são investigados, buscando expandir as fronteiras da inteligência artificial e suas aplicações.



TEMA 2 – MACHINE LEARNING E CIÊNCIA DE DADOS

Nesta seção será dado foco na área de machine learning, ou aprendizagem de máquina. Apresentaremos as definições básicas, o funcionamento e como a aprendizagem de máquina está intimamente relacionada com a ciência de dados, sendo uma importante e poderosa ferramenta, não apenas para essa área do conhecimento, mas para muitas outras.

2.1 A aprendizagem de máquina

A expressão Machine Learning foi usada pela primeira vez pelo pioneiro da inteligência artificial Arthur Lee Samuel, que a definiu como “um campo de estudo que dá aos computadores a capacidade de aprender sem que tenham sido explicitamente programados para tal”. Mas o que exatamente é Machine Learning?

Machine Learning atualmente é considerada como uma subárea da Inteligência Artificial, e nós devemos diferenciá-la dos métodos de Inteligência Artificial (IA) que lidam com problemas de busca, agentes inteligentes e resolução de problemas, como por exemplo fazer com que o computador consiga definir a melhor jogada em uma partida de xadrez ou encontrar a saída de um labirinto. Essa área da Inteligência Artificial atualmente é referenciada como IA clássica, já a área de Machine Learning pode ser compreendida como um conjunto de técnicas ou métodos que permitem às máquinas aprender por meio de exemplos.


Sistemas especialistas e sistemas de recomendação, com abordagens mais clássicas, são criados segundo um conjunto de regras que podem mudar ao longo do tempo. Essas mudanças colocam os desenvolvedores de sistemas numa situação em que o conjunto de regras do sistema necessita de revisão e atualização constante. Esse tipo de trabalho, ao longo do tempo, torna-se inviável, principalmente pela dificuldade de se evitar que uma regra influencie na outra à medida que o número de regras aumenta.

Tomemos como exemplo, um problema clássico de Machine Learning: a detecção de *spams* em serviços de correio eletrônico. O fluxo de dados e o processamento de um sistema antispam básico deve obedecer ao diagrama apresentado na Figura **Erro! Fonte de referência não encontrada.** A



“inteligência” desse programa está no conjunto de regras e a evolução desse mecanismo se dá pela avaliação dos erros, que normalmente é informado por um humano. Não sendo possível para o programa avaliar ou contrariar a informação do humano, baseado apenas no seu próprio conhecimento do problema.


Figura 1 – Sistema baseado em regras



Uma abordagem utilizando Machine Learning para o problema de detecção de spams não conta e nem depende de um conjunto de regras. A sua inteligência está em aprender considerando o modo como estão distribuídos os dados naquele contexto. Assim, se houver mudança na maneira com os spams são escritos ou como são enviados, os algoritmos necessitarão apenas que sejam fornecidos exemplares dos novos tipos. Assim, o algoritmo aprende a identificar novas instâncias, ainda que não tenha sido preparado para isso ou explicitamente receba instrução para tanto. A Figura **Erro! Fonte de referência não encontrada.** ilustra o fluxo de dados e o funcionamento de um sistema baseado em aprendizagem de máquina para detecção de spam.



Figura 2 – Sistema antispam baseado em aprendizagem de máquina




Uma grande vantagem dos métodos de Machine Learning em problemas como detecção de spam é que o processo de aprendizagem pode ser automatizado à medida que novos exemplos são identificados e apresentados ao algoritmo, como podemos ver pela Figura **Erro! Fonte de referência não encontrada..** Esse processo, em certa medida, necessita do acompanhamento de um humano para avaliar a maneira como está evoluindo e para evitar que ele se torne excessivamente especializado e apresente variabilidade nas suas decisões ou venha a detectar erroneamente como spam um e-mail válido ou importante.

2.2 A Ciência de Dados

Com todas as mudanças causadas pelos avanços da IA nas mais diversas áreas, novas técnicas, novos métodos e novas áreas do conhecimento surgiram. Assim aconteceu com o surgimento da área conhecida como *Data Science* ou *Ciência de Dados*, sendo comum o termo se confundir com Machine Learning ou ser referenciado pela expressão *Inteligência de Dados*. A Figura 3 ilustra o relacionamento entre a inteligência artificial, a aprendizagem de máquina e a ciência de dados.



Figura 1 – Relação entre Aprendizagem de Máquina e Ciência de Dados



A Ciência de Dados é uma área interdisciplinar que busca gerar ou extrair conhecimento de um conjunto de dados, estruturados e não estruturados. Dados estruturados são aqueles que desde o momento do seu recebimento por sistemas computacionais já apresentam um padrão de organização ou estrutura. Um dos exemplos mais comuns são os dados armazenados em bancos de dados relacionais. Já os dados não estruturados são aqueles que, ainda que apresentem alguma estrutura, a sua forma de armazenamento é heterogênea e os formatos, bem como os tipos de dados, podem ser variados. Como, por exemplo, um repositório de arquivos que pode conter diversos tipos de arquivos, como documentos de texto, planilhas, imagens, vídeos e outros.

Os profissionais de ciências de dados utilizam diversas ferramentas, como modelos estatísticos, modelos de pesquisa operacional e ferramentas computacionais; dentre estas últimas, os modelos de aprendizagem de máquina. Assim, podemos ver que a Ciência de Dados não engloba a Aprendizagem de Máquina, mas a utiliza como ferramenta para as suas tarefas. Essas tarefas são dos mais diversos tipos, com destaque para propaganda digital, reconhecimento de imagens, logística, saúde, *e-commerce*, análises financeiras, comparação de preços e outros.



2.3 Diferentes, mas semelhantes

Ainda que a Aprendizagem de Máquina e a Ciência de Dados não sejam a mesma coisa, nem necessariamente estejam contidas uma na outra, elas apresentam algumas semelhanças que vale a pena destacar, como a necessidade de organizar dados, transformá-los em informação relevante para o problema a ser resolvido e, assim, poder transformar essa informação em uma representação relacionada ao problema para o qual buscamos uma solução.

TEMA 3 – DADO, INFORMAÇÃO E ATRIBUTO

Abordaremos nesta seção o que diferencia dados, informação e atributos. Também apresentaremos a importância dos atributos para os métodos de Aprendizagem de Máquina.



3.1 Dado, informação e conhecimento

A relação entre os termos *dado*, *informação* e *conhecimento* é muito estreita, com os termos comumente sendo utilizados como sinônimos, mas é necessário estabelecer diferenças entre eles para definir a importância e o tipo de tratamento necessário para cada um deles.

Dados se refere a medições ou registros de observação, anotados considerando determinada escala, conjunto de valores ou por uma representação numérica. Se você nasceu no ano de 1998 e esse dado foi registrado, ele por si só não nos fornece muito a seu respeito. No entanto, se considerarmos que estamos no ano de 2020, podemos concluir que você possui, ou completará, 22 anos este ano. Com esse processamento – cálculo de idade – temos uma informação sobre você.

Ao avançarmos um pouco mais na análise sobre você considerando seu ano de nascimento e sua provável idade em 2020, podemos concluir que você já possui o direito de votar e pode ser considerado maior de idade. Esse conhecimento foi adquirido ao aproveitarmos a informação que processamos ao calcular a sua idade e conciliá-la com a informação de que, no Brasil, as pessoas maiores de 18 anos devem votar e são consideradas civilmente capazes. Assim, podemos considerar as seguintes etapas de coleta e avaliação até obtermos conhecimento sobre um dado fornecido:

- Sua data de nascimento: 10 de julho de 1998;
- Informação em 11 de julho de 2020: idade – 22 anos;
- Conhecimento: maior de idade, com direito a votar.

Partindo do nosso exemplo apresentado, podemos considerar que dados são fatos sobre o mundo ou entidades (como você) que dele façam parte. Já informação é algo que somente aparece quando processamos estes dados, dando-lhes valor e significado, ao passo que o conhecimento é uma espécie de inferência que podemos fazer sobre as informações colhidas com base na experiência e em um conjunto de regras definidas pelas informações anteriormente obtidas. Esse tipo de inferência é o tipo de comportamento inteligente que os métodos de aprendizagem de máquina quando aplicados aos problemas de ciência de dados tentam simular ou buscar uma aproximação.



3.2 Tipos de dados

Os dados, de forma geral, podem agrupados de duas maneiras: dados numéricos e categóricos. Estes, por sua vez, também podem ser organizados em grupos distintos, da seguinte forma:

- Dados numéricos: quaisquer valores ou observações que possam ser mensurados:
 - Dados discretos: dados cujos valores são distintos e separados uns dos outros. De forma genérica, podemos considerar como dados que não podem ser medidos, mas podem ser contados. Um exemplo é o número de parentes de uma pessoa, pois uma pessoa somente pode ter uma quantidade inteira de parentes.
 - Dados contínuos: dados cujos valores representam medidas e que, de forma genérica, não podem ser contados, mas podem ser medidos. Um exemplo, é a altura ou o peso de uma pessoa, que é representada por um número real que pode ser representado como 1,70 m ou 169,9 cm, e apresentar um grau de imprecisão relacionado ao instrumento de medição ou a outros fatores, não sendo possível determinar de maneira categórica o seu valor, nem tão pouco contar, pois, no nosso exemplo da altura, se escolhermos a unidade de medida como metros ou centímetros as quantidades serão diferentes.
- Dados categóricos: dados que representam características como gênero, estado civil, grau de instrução etc.:
 - Dados nominais: dados categóricos que representam valores discretos que não envolvam valor quantitativo e não apresentam algum tipo de relacionamento de ordem ou posição entre si. Um exemplo desse tipo de dado é a lista dos idiomas que uma pessoa fala.
 - Dados ordinais: dados categóricos, que representam valores discretos que possuem uma relação de ordem entre si. Um exemplo de dados ordinais é a lista de opções de grau de instrução Ensino Básico, Ensino Médio, Graduação, Pós-graduação.

Entender os diferentes tipos de dados é importante, pois ao realizarmos tarefas como análise de dados ou execução de métodos de aprendizagem de máquina, a caracterização das entidades envolvidas nos problemas a serem



resolvidos são representados por diferentes tipos de dados, que devem ser considerados nas suas diferenças, não sendo possível analisar dados contínuos e categóricos da mesma forma, pois os métodos utilizados para um tipo dificilmente serão adequados para os outros.

3.3 Atributos e características

Atributos são propriedades de um fenômeno ou entidade que podem ser mensurados como um dado categórico ou numérico. Eles são importantes, pois são os responsáveis por descrevem de forma matemática os problemas a serem resolvidos com métodos de aprendizagem de máquina. Tamanho é a importância da representação dos atributos para os métodos de aprendizagem de máquina que o termo *Engenharia de Atributos* foi cunhado para referir-se às técnicas de seleção, construção e extração de atributos.

Um atributo pode ser tanto um dado quanto uma informação acerca de uma entidade ou fenômeno. Ao tentarmos ensinar um programa a reconhecer e-mails que são spam, a presença ou ausência de uma lista de palavras-chave, a linguagem utilizada, a presença ou não do remetente na sua lista de contatos, a repetição de determinados termos e o grau de semelhança com outros e-mails que já se sabe serem spam são exemplos de atributos, cujos valores podem descrever aquelas instâncias que podem ser consideradas como spam.

De acordo com Géron (2017), o termo atributo (em inglês *attribute*) se refere ao tipo de dado utilizado e o termo característica (em inglês *feature*) se refere ao atributo mais o seu valor. No entanto, é comum encontrarmos em diversas fontes o uso dos termos como equivalentes.

Em aprendizagem de máquina, ao escolhermos o conjunto de características que vamos utilizar para definir as entidades do nosso problema, em geral, esse conjunto de características é referenciado como vetor de características ou atributos e possui uma dimensão que depende do número de atributos utilizados. Por exemplo, se quisermos definir o vetor de atributos de uma pessoa cliente, podemos utilizar a seguinte lista de atributos:

- Posição 1: idade (em anos)
- Posição 2: nacionalidade (0 – brasileiro, 1 – estrangeiro)
- Posição 3: altura (em metros)
- Posição 4: peso (em quilos)



- Posição 5: sexo (0 – masculino, 1 – feminino)
- Posição 6: gosta de futebol (0 – não, 1 – sim)
- Posição 7: salário (em reais)

Assim, podemos descrever duas pessoas distintas, por meio das seguintes características:

- Cliente: Marcel da Silva (homem brasileiro, 22 anos de idade, altura de 1,70m, peso 75kg, que gosta de futebol e recebe R\$ 2.500,00 de salário)

posição	1	2	3	4	5	6	7
dados	22	0	1,70	75	0	1	2.500,00

- Cliente: Ruan del Silva (homem mexicano, 52 anos de idade, altura de 1,75m, peso 80kg, que gosta de futebol e recebe R\$ 2.500,00 de salário)

posição	1	2	3	4	5	6	7
dados	52	1	1,75	80	0	1	2.500,00

Assim, o nosso vetor de atributos possui dimensão 7 e o espaço vetorial determinado por esses vetores é chamado de espaço de características. A dimensionalidade desse espaço é determinada pelo tamanho dos vetores (ou quantidade de atributos) utilizados. Normalmente, os tamanhos de vetores utilizados ultrapassam as centenas, e alguns modelos voltados para problemas de reconhecimento de imagens podem ter dimensões ultrapassando os milhares. Um conjunto de clientes e seus vetores de características são exibidos na Figura **Erro! Fonte de referência não encontrada..**

Figura 4 – Conjunto de vetor de características de um grupo de clientes


	idade	nacionalidade	altura	peso	sexo	gosta de futebol	salario	
0	22		0	1.70	75	0	1	2500
1	52		1	1.75	80	0	1	2500
2	31		1	1.50	65	1	1	4500
3	65		1	1.95	86	0	0	6500
4	17		0	1.81	95	0	1	1500
5	54		0	1.65	80	1	0	3500
6	30		0	1.90	105	1	1	1200
7	25		1	1.85	65	1	1	2245
8	49		0	1.71	75	0	0	25000
9	26		1	1.81	80	1	1	8000



Conforme podemos ver pela Figura **Erro! Fonte de referência não encontrada.**, todos os valores dos atributos considerados foram convertidos para valores numéricos. Mesmo atributos cujos valores não são numéricos, como sexo, nacionalidade e gosto por futebol, foram convertidos para valores numéricos discretos. Conforme citamos anteriormente, os modelos de aprendizagem devem lidar com valores numéricos, razão pela qual também se nota a ausência do nome dos clientes, que também é um atributo que permite descrever uma pessoa, mas para o nosso exemplo teria pouca relevância para o problema e não poderia ser convertido em um valor numérico.

Dependendo dos atributos que forem selecionados, os dados podem ser visualizados de maneiras distintas e fornecer conhecimento sobre os dados analisados. As informações contidas nos vetores de características do nosso exemplo permitem agrupar os clientes em grupos que recebam ofertas de material esportivo, pois eles gostam de futebol, conforme podemos ver na Figura **Erro! Fonte de referência não encontrada.** É fácil perceber que, ao analisarmos esse grupo de dados considerando 3 atributos (idade, salário e gosto por futebol), existe uma separação clara entre dois grupos separados por uma linha em azul. Essa linha é um bom exemplo de como um modelo de aprendizagem de máquina funciona determinando uma separação entre grupos distintos e aprendendo como posicionar os novos clientes que tiverem o seu vetor de características fornecido para o modelo.

Figura 5 – Gráfico de clientes com indicação se gostam de futebol





O uso de métodos de aprendizagem de máquina para resolver problemas segue um fluxo semelhante ordenado da seguinte forma:

1. Estudar e compreender o problema
2. Seleção e preparação dos dados
3. Estudo e descoberta de conhecimento com base nos dados
4. Seleção, extração e conversão dos atributos
5. Escolha e treinamento de um modelo de aprendizagem
6. Ajustes do modelo escolhido e dos dados
7. Provisionamento do modelo em produção
8. Acompanhamento e avaliação do desempenho do modelo

As etapas iniciais exigem primeiro entender o problema que está sendo abordado e com o conhecimento do problema determinar quais atributos utilizar para representar os elementos componentes do problema. A escolha dos atributos influencia diretamente os resultados obtidos. Não há um consenso sobre quais estratégias são melhores, nem qual a quantidade ideal de atributos (tamanho do vetor) ou quais tipos utilizar. Tudo isso está intrinsecamente relacionado ao problema que se deseja resolver e a melhor forma de fazer isso; pode ser considerada uma mistura de ciência e arte que se adquire por meio da prática e experiência.

TEMA 4 – TIPOS DE APRENDIZAGEM

Na seção anterior falamos sobre vetores de atributos e o espaço vetorial que eles determinam, bem como da importância desses atributos para os métodos utilizados em aprendizagem de máquina. Nesta seção vamos conversar um pouco sobre os tipos de aprendizagem e isso deixará mais clara a importância dos atributos e como estes podem ser utilizados.

Como você já sabe, após a extração e seleção de atributos, os vetores de atributos servem como entradas para os métodos de aprendizagem de máquina. Esses métodos utilizam as informações fornecidas para criar um conhecimento sobre como os dados fornecidos estão organizados e distribuídos. A escolha do método que será utilizado, assim como no caso dos atributos, depende do problema e comumente são categorizados da seguinte forma:

- métodos supervisionados ou preditivos;
 - classificação



- regressão
- métodos não supervisionados ou descritivos;
 - associação ou correlação
 - agrupamento
 - detecção de *outliers*¹
- métodos semissupervisionados;
- métodos de aprendizagem por reforço.

4.1 Aprendizagem supervisionada

Os métodos de aprendizagem supervisionada são aqueles cujos dados fornecidos para o processo de aprendizagem e incluem exemplos com a identificação da solução desejada. Em tarefas como a classificação de spam, os dados fornecidos para ensinar ao modelo, já possuem uma identificação na qual indicam se cada instância fornecida é ou não spam. Os diferentes valores que identificam cada instância fornecida durante a aprendizagem, serão os únicos que poderão ser obtidos do modelo aprendido. Assim, um modelo de classificação que recebe milhares de exemplos de e-mails que possuem apenas duas identificações, spam ou não spam, somente poderá fornecer um desses valores como saída.

A informação que identifica cada instância de um problema de classificação recebe o nome de classe ou rótulo. A classe é um atributo cujos valores são discretos. Suponhamos que você precise desenvolver um classificador de e-mails, que será responsável pela identificação de mensagens de correio eletrônico recebidas em spam e não spam. Para isso, devemos avaliar quais atributos das mensagens iremos utilizar e como serão os vetores de características de cada instância considerada.

Os atributos utilizados para descrever as instâncias do nosso problema, podem ser dos mais diversos, como a indicação de presença ou ausência de alguma parte, uma contagem ou um valor que identifique aquela instância. Para exemplificar um processo de identificação de mensagens de e-mail em spam e

1 O termo *outliers* se refere a uma instância (valor ou medida) que apresenta um grande distanciamento em relação aos demais da amostra.



não spam, mostramos a seguir um conjunto de atributos e os seus respectivos vetores de características:

Quadro 1 – Conjunto de atributos e vetores de características

POSIÇÃO	ATRIBUTO	VALORES POSSÍVEIS
1	ID da Mensagem	00001 - 10000
2	Remetente conhecido?	0 – não, 1 – sim
3	Idioma	0 – Português, 1 - Outros
4	Palavras como herança, prêmio ou pagamento aparecem no texto?	0 – não, 1 – sim
5	Quantidade de erros gramaticais?	0 - 1000
6	Quantidade de vezes que seu nome aparece no texto?	0 - 1000
7	Mensagem tem assinatura?	0 – não, 1 – sim
8	Classe/Rótulo	0 – spam, 1 - não-spam

	ATRIBUTOS (1-7)							CLASSE
mensagem 01	01	0	1	1	10	0	0	0 (spam)
mensagem 02	02	0	1	1	5	0	0	0 (spam)
mensagem 03	03	0	0	1	19	0	0	0 (spam)
mensagem 04	04	1	0	0	0	1	1	1 (não-spam)
mensagem 05	05	1	0	0	1	2	1	1 (não-spam)

Os vetores de características listados anteriormente são fornecidos para o modelo de aprendizagem com a indicação das classes de cada um dos exemplos. Assim, quando uma nova mensagem for recebida, contendo o seguinte vetor de características:


	ATRIBUTOS (1-7)							CLASSE
mensagem 06	06	0	1	1	20	0	0	?

O conjunto de vetores de características das 0 mensagens apresentadas anteriormente serão entregues para o modelo de aprendizagem, para que ele aprenda, baseado nos vetores de características como identificar se novas mensagens são ou não spam. Todo o processo de distribuição dos dados fornecidos durante o processo de aprendizagem do nosso exemplo, bem como



a identificação de uma nova mensagem recebida, pode ser visualizado na Figura **Erro! Fonte de referência não encontrada..**

Figura 6 – Modelo simplificado de um modelo de aprendizagem para classificação de e-mails



O modelo, baseando-se no conhecimento adquirido dos modelos anteriores, classificará a mensagem com a classe “0 (spam)”. Uma grande vantagem dos modelos supervisionados é a possibilidade de avaliarmos o desempenho dos modelos, pois eles podem ser testados com exemplares diferentes daqueles utilizados durante o processo de aprendizagem; porém, a obtenção desses exemplares pode ser difícil, pois os modelos necessitam de grandes quantidades de exemplos para aprender e o processo de rotulação dos exemplares deve ser feito de forma cuidadosa. Se os exemplares fornecidos durante o processo de aprendizagem do modelo estiverem rotulados de forma errada, o modelo aprenderá de forma errada ou, no pior dos casos, não conseguirá diferenciar de maneira clara as categorias do problema para o qual foi treinado.

Os modelos de classificação são uma boa opção quando o problema que estamos tentando resolver pode ser delimitado por uma lista de valores categóricos, como no caso do nosso detector de spam simplificado. Porém, nem todos os problemas podem ser resolvidos com o uso de atributos discretos. Assim, em problemas como a predição do preço de um carro, não podemos fornecer apenas valores categóricos, mas sim um valor numérico. Para



problemas desse tipo, devem ser utilizados métodos supervisionados de regressão.

Os métodos supervisionados regressivos também recebem informações sobre as suas instâncias, porém essa informação é um valor numérico, bem como a saída do seu modelo. Assim, se precisamos criar um modelo que consiga prever o valor de venda de um carro, devemos fornecer vários exemplares de vetores de características de carros que já foram vendidos e qual foi o valor da venda. Assim, o modelo aprenderá como estimar o valor do preço de um carro diferente de todos aqueles que ele já conhece.

Estes são alguns dos algoritmos supervisionados:

- Árvores de decisão
- Classificador bayesiano
- Regressão linear
- k-Vizinhos mais Próximos (kNN²)
- Redes neurais

4.2 Aprendizagem não supervisionada

Os métodos de aprendizagem não supervisionada são aqueles que conseguem lidar com dados que não receberam uma rotulação prévia ou sobre os quais não se possui informação da sua organização e estrutura. Diferentemente dos métodos supervisionados, eles se assemelham a um aluno que tenta aprender sem um professor. Assim, por não dispor de uma informação que descreva os exemplares recebidos para aprendizagem, os modelos não supervisionados buscam aprender com base nos dados, explorando relacionamento entre os diferentes atributos, avaliando similaridades e diferenças entre os exemplares e, dessa forma, determinando grupos ou classes para as instâncias. Uma vez que uma organização dos dados tenha sido aprendida, ao receber novas instâncias o modelo utilizará esse conhecimento para identificá-las dos seus vetores de características.

Suponhamos que você necessite criar um modelo para um aplicativo de relacionamentos. Não há como ter de antemão a informação de quais pessoas irão despertar interesse mútuo, mas você sabe que os usuários buscam pessoas

2 Do inglês k-Nearest Neighbors



que gostam dos mesmos tipos de atividades e tenham os mesmos interesses que elas. Assim, um exemplo de conjunto de 5 usuários do aplicativo poderá ser descrito por meio dos seguintes atributos, com os seus respectivos vetores de características:

Quadro 2 – Aplicativo de relacionamentos

POSIÇÃO	ATRIBUTO	VALORES POSSÍVEIS
1	ID	1 - 5
2	Idade	18 - 100
3	Gosta de esportes?	0 – não, 1 – sim
4	Gosta de ler?	0 – não, 1 – sim
5	Gosta de filmes?	0 – não, 1 – sim
6	Cidade/Estado onde mora?	Código do Município
7	Sexo	0 – masculino, 1 – feminino

	ATRIBUTOS (1-7)						
usuário 01	01	22	0	0	1	4106902	1
usuário 02	02	30	1	1	1	4105508	0
usuário 03	03	40	0	1	1	4106902	1
usuário 04	04	35	0	1	1	4105508	1
usuário 05	05	26	0	0	1	4106902	0

Não foram fornecidos rótulos que permitam caracterizar os usuários do aplicativo e, assim, agrupá-los de acordo com os seus interesses. Os dados dos vetores de características dos usuários serão organizados conforme mostrado na Figura **Erro! Fonte de referência não encontrada..**


Figura 7 – Vetores de características usuários de aplicativo de relacionamento

	id	idade	gosta de esportes	gosta de ler	gosta de filmes	codigo municipio	sexo
0	1	22	0	0	1	4106902	1
1	2	18	1	1	1	4105508	0
2	3	40	0	1	1	4106902	1
3	4	35	0	1	1	4105508	1
4	5	26	0	0	1	4106902	0



Claramente, podemos ver que os usuários 1 e 5, formam um grupo, ao passo que os usuários 3 e 4 formam um segundo grupo, pois possuem exatamente os mesmos interesses. Entretanto, a qual grupo o usuário 2 deve pertencer, se considerarmos a existência de apenas dois grupos? Um método de agrupamento não supervisionado, partindo por exemplo de uma regra como a soma total dos interesses em comum, escolheria o mesmo grupo dos usuários 3 e 4, pois eles possuem mais interesses em comum com o usuário 2. Essa decisão é tomada pelo modelo, sem que ninguém tenha lhe dito onde posicionar o usuário 2. Esse resultado pode ser visto na Figura **Erro! Fonte de referência não encontrada.**, em que é possível notar que realmente existe uma proximidade maior do usuário 2 com o grupo ao qual foi atribuído.

Figura 8 – Grupos gerados por método não-supervisionado



Uma das principais aplicações de métodos não supervisionados reside no agrupamento e busca de similaridades entre os vetores de características das instâncias do problema a ser resolvido. Para isso, diversos algoritmos podem ser utilizados, cada um com a sua abordagem característica. Estes são alguns dos algoritmos supervisionados:

- k-Means
- HCA (Hierarchical Cluster Analysis)
- DBSCAN (Density-Based Spatial Clustering of Application with Noise)



TEMA 5 – FERRAMENTAS NECESSÁRIAS

Nas seções anteriores você aprendeu sobre os vetores de características e que eles são formados por valores numéricos, e também aprendeu sobre a importância desses vetores para os modelos de aprendizagem de máquina. A aprendizagem de máquina pode parecer mágica, mas na verdade se trata de matemática aplicada. Assim, para lidar com todos os cálculos, desenvolvimento de programas, monitoramento dos resultados dos modelos e disponibilização destes em produção precisamos de algumas ferramentas para executar essas tarefas.

5.1 Linguagem de programação

A primeira ferramenta que precisamos escolher deve ser uma linguagem de programação, na qual poderemos desenvolver os algoritmos e os programas que irão executar toda a preparação e tratamento de dados, seleção de atributos e o desenvolvimento dos algoritmos e modelos de aprendizagem. Utilizaremos a linguagem de programação Python 3.6, por se tratar da linguagem mais utilizada para tarefas de aprendizagem de máquina e ciência de dados. A escolha da linguagem de programação servirá como guia para a escolha dos demais componentes necessários.

A linguagem Python pode ser utilizada por meio da instalação de uma distribuição. Há diversas opções de instalação que podem ser facilmente encontradas em sites dos seus respectivos projetos. Uma distribuição que contém todos os módulos que necessitaremos é a Anaconda.

5.2 Demais módulos

Após escolhermos a linguagem de programação será necessário obter módulos que possam ser utilizados para seguintes tarefas. Como nossa escolha foi pela linguagem Python, utilizaremos os seguintes módulos para cada uma das tarefas a seguir:

- Tratamento e manipulação de dados: biblioteca Pandas;
- Processamento numérico: biblioteca Numpy;
- Algoritmos de aprendizagem de máquina: biblioteca Scikit-learn;
- Visualização de dados: biblioteca Matplotlib.



Com esses módulos em mão e um conhecimento da sintaxe e funcionamento da linguagem Python, teremos todas as ferramentas necessárias para a criação, treinamento e utilização dos nossos modelos.

FINALIZANDO

Nesta aula abordamos a história da Inteligência Artificial, sua evolução e todas as transformações que essa área sofreu, tornando-se uma forte e valiosa indústria e apresentamos como os métodos de aprendizagem de máquina, hoje fazem parte do nosso cotidiano e motivou o surgimento de novas abordagens e novas profissões na busca de informações com base nos dados. Vimos também a distinção entre dado e informação, destacando o que são os atributos e como a sua escolha pode ser um fator determinante na qualidade dos resultados obtidos pelos modelos de aprendizagem de máquina, bem como mostramos quais tipos de aprendizagem podem ser utilizados e como eles podem ser aplicados a problemas reais. Uma segunda leitura do texto pode ajudar a fixar os conceitos.



REFERÊNCIAS

GÉRON, A. **Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow**: concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

RUSSEL, S. J.; NORVIG, Peter. **Inteligência Artificial**: uma abordagem moderna. Rio de Janeiro: Elsevier, 2013.