



MODELAGEM ESTATÍSTICA

AULA 1



Prof. Guilherme Augusto Pianezzer



CONVERSA INICIAL

Seja bem-vindo(a)! Nesta aula você aprenderá algumas das principais análises estatísticas para a descrição de dados. Entre elas, tomará conhecimento sobre a Análise de Variância, também conhecida como ANOVA, para um e dois fatores, e sobre os métodos de regressão linear, múltipla e não linear.

Em cada aula, você será convidado a refletir sobre a construção dos modelos estatísticos e a aplicação desses modelos em dados reais. Para isso, discutiremos o problema de inferência estatística apresentando as principais distribuições amostrais, binomiais e normais, além de teoremas centrais no entendimento de Estatística.

TEMA 1 – MODELO ESTATÍSTICO

Ao descrever a característica de uma população, podemos enfrentar dificuldades em relação à sua quantidade de elementos. Como exemplo, analisar a proporção exata de pessoas que votariam no candidato A na próxima eleição para presidente envolve uma pergunta para cada cidadão brasileiro. Para contornar essa dificuldade, a inferência estatística busca criar generalizações para a população tomando como base evidências fornecidas por uma de suas amostras.

1.1 Algumas definições

Para compreender o modelo estatístico básico de inferência estatística, alguns termos precisam ser compreendidos. Chamamos de **variável aleatória** a característica numérica de um determinado experimento, a qual pode ser interpretada, matematicamente, como uma função que associa um número real a cada elemento do espaço amostral. Chamamos de **população** o conjunto de todos os elementos de uma determinada situação; citamos a população brasileira, mas poderíamos nos referir também aos parafusos recebidos em determinado lote.

Um subconjunto da população é considerado sua **amostra**, na qual as propriedades observáveis de cada elemento podem ser medidas. Chamamos de **parâmetro** uma característica numérica desconhecida sobre a distribuição dos elementos dessa população. O **estimador** é uma função extraída com base na



amostra e tem como objetivo representar um parâmetro de interesse da população; seu valor numérico é conhecido como **estimativa**.

1.2 Modelo estatístico

Ao longo da disciplina, quando cada um dos modelos estatísticos é apresentado, nossa finalidade é modelar alguns sistemas de interesse em relação a algumas de suas características. Tais modelos são construídos com base num conjunto de observações das realizações das variáveis aleatórias e na família de distribuição associada. Nosso objetivo é expressar (ou descrever) o resultado de uma variável resposta, y , como função de uma ou mais variáveis, x_n , ou seja:

$$y = f(x_1, x_2, \dots, x_n).$$

Entretanto, ao tratarmos de problemas reais, percebemos que na maior parte dos casos não conseguimos criar um modelo ideal para uma ampla gama de situações; criamos hipóteses simplificadoras, reduzimos a quantidade de variáveis de controle. Em suma, à medida que escolhemos estratégias para descrever o problema nos afastamos da realidade e geramos um efeito acumulativo de erro. Assim, podemos concluir que:

$$y = f(x_1, x_2, \dots, x_n) \pm \varepsilon$$

Nesse caso, ε representa esse efeito de erro. Concluimos então que a coleção de variáveis que compõem esse erro não pode ser controlada; em vários casos, não são nem observáveis. É essa característica que evidencia a **aleatoriedade** que define qualquer tipo de modelo estatístico.

TEMA 2 – DISTRIBUIÇÕES AMOSTRAIS

Desejamos compreender o conceito de distribuição amostral. Para isso, verifica-se que toda amostra aleatória de n elementos é representada por

$$X_1, X_2, \dots, X_n,$$

São variáveis aleatórias, em que cada termo representa um elemento da amostra. Sendo dois elementos dessa amostra, X_i e X_j , independentes com a mesma função de densidade de probabilidade, $\forall i \neq j$. Então, concluimos que seus elementos são **independentes** e igualmente distribuídos. Veja que as



principais suposições realizadas em inferência estatística dependem deste critério. Além disso, $T(x_1, x_2, \dots, x_n)$ é considerada uma **estatística** ou **estimador** e sua distribuição de probabilidade é chamada **distribuição amostral**.

2.1 Média aritmética, variância amostral e desvio-padrão amostral

Considerando a amostra aleatória com n elementos de uma população, definida como $(X_1, X_2, \dots, X_n)$, a média aritmética ($\bar{X}$), variância amostral (s^2) e desvio-padrão amostral (s) são considerados estatísticas, definidas como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{X_1 + X_2 + \dots + X_n}{n}$$
$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$
$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$


2.2 Exemplo: distribuição amostral da média $\bar{X}$

Como exemplo, veremos a distribuição amostral para a média $\bar{X}$ de um conjunto de dados. Para isso, imagine uma urna com quatro bolas numeradas de 1 a 4 e X como variável aleatória que registra o sorteio de uma bola. Veja que

$$P(\bar{X} = 1) = P(\bar{X} = 2) = P(\bar{X} = 3) = P(\bar{X} = 4) = 0,25$$

possuem a mesma chance de ocorrência. A Figura 1 apresenta a distribuição amostral da média considerando essa única ocorrência.

Figura 1 – Distribuição amostral da média para um único sorteio entre quatro bolas





Podemos concluir que no caso em que temos uma amostra de tamanho unitário, a distribuição amostral da média é a mesma da variável aleatória X .

Para prosseguirmos na análise, imagine a retirada, de forma independente e com reposição, de duas bolas, X_1 e X_2 . Nesse caso, podemos ter as seguintes situações:

$X_1 = 1, X_2 = 1, \bar{X} = 1$	$X_1 = 3, X_2 = 1, \bar{X} = 2$
$X_1 = 1, X_2 = 2, \bar{X} = 1,5$	$X_1 = 3, X_2 = 2, \bar{X} = 2,5$
$X_1 = 1, X_2 = 3, \bar{X} = 2$	$X_1 = 3, X_2 = 3, \bar{X} = 3$
$X_1 = 1, X_2 = 4, \bar{X} = 2,5$	$X_1 = 3, X_2 = 4, \bar{X} = 3,5$
$X_1 = 2, X_2 = 1, \bar{X} = 1,5$	$X_1 = 4, X_2 = 1, \bar{X} = 2,5$
$X_1 = 2, X_2 = 2, \bar{X} = 2$	$X_1 = 4, X_2 = 2, \bar{X} = 3$
$X_1 = 2, X_2 = 3, \bar{X} = 2,5$	$X_1 = 4, X_2 = 3, \bar{X} = 3,5$
$X_1 = 2, X_2 = 4, \bar{X} = 3$	$X_1 = 4, X_2 = 4, \bar{X} = 4$

Veja que a partir da contagem dessas possibilidades, podemos encontrar a probabilidade de ocorrência de cada valor para a média, obtendo, assim:

$$P(\bar{X} = 1) = \frac{1}{16} = 0,0625$$

$$P(\bar{X} = 1,5) = \frac{2}{16} = 0,125$$

$$P(\bar{X} = 2) = \frac{3}{16} = 0,1875$$

$$P(\bar{X} = 2,5) = \frac{4}{16} = 0,25$$


$$P(\bar{X} = 3) = \frac{3}{16} = 0,1875$$

$$P(\bar{X} = 3,5) = \frac{2}{16} = 0,125$$

$$P(\bar{X} = 4) = \frac{1}{16} = 0,0625$$




Figura 2 – Distribuição amostral da média para dois sorteios entre quatro bolas (independentes e com reposição)



De forma similar, podemos encontrar a distribuição amostral da média para n sorteios. À medida que fazemos $n \rightarrow \infty$ esse gráfico vai se aproximando do tão conhecido gráfico da distribuição normal. A Figura 3 apresenta alguns gráficos de distribuição normal que são construídos com os diferentes valores de média e desvio padrão.

Figura 3 – Exemplos de gráficos da distribuição normal.



TEMA 3 – LEI FRACA DOS GRANDES NÚMEROS E TEOREMA CENTRAL DO LIMITE

Dada uma função densidade de probabilidade, $f(\cdot, \theta)$ como a desenvolvida no exemplo anterior, no qual a variável aleatória tem valor esperado μ . Como discutido no início da aula, não podemos realizar medições acerca de toda a população. Então, como podemos retirar valores confiáveis sobre o valor esperado de X , $E(x)$?



3.1 Lei Fraca dos Grandes Números

Desejamos, portanto, encontrar a probabilidade de que $\bar{X} - \mu$ esteja dentro de uma zona aceitável, digamos, $1 - \delta$. Em outras palavras, gostaríamos de concluir que

$$P(-\epsilon < \bar{X} - \mu < \epsilon) \geq 1 - \delta$$

indicando que o valor esperado e o valor real estejam suficientemente próximos.

Veja que para toda variável aleatória X e toda função não negativa h , podemos escrever, para $k > 0$,

$$P(h(X) \geq k) \leq \frac{E(h(X))}{k}.$$

Como os eventos $h(X) \geq k$ e $h(X) < k$ são complementares, é equivalente escrever

$$P(h(x) < k) \geq 1 - \frac{E(h(x))}{k}$$

No caso em que $h(X) = (\bar{X} - \mu)^2$ e $k = \epsilon^2$, podemos obter

$$P(\epsilon < \bar{X} - \mu < \epsilon) = P(|X - \mu| < \epsilon) = P(|\bar{X} - \mu|^2 < \epsilon^2)$$

Assim, unindo os resultados encontrados, verificamos que

$$P(|\bar{X} - \mu| < \epsilon) \geq 1 - \frac{E((\bar{X} - \mu)^2)}{\epsilon^2} = 1 - \frac{\frac{\sigma^2}{n}}{\epsilon^2} \geq 1 - \delta$$

Esse resultado é conhecido como **Lei Fraca dos Grandes Números**. A interpretação desse teorema é perceber que à medida que a amostra cresce, a média dos resultados obtidos se aproxima da média da população. Inúmeras versões desse teorema e suas respectivas demonstrações podem ser encontradas na literatura estatística.

3.2 Teorema Central do Limite

Quando analisamos uma função densidade de probabilidade f , como do exemplo anterior, no qual possui média μ e variância σ^2 , o Teorema Central do Limite afirma que a variável aleatória

$$Z_n = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$



tende a se tornar a distribuição normal padrão (i.e., $\mu = 0$ e $\sigma^2 = 1$) quando $n \rightarrow \infty$. Esse, que é um dos principais resultados de toda a Estatística, visto que para qualquer amostra suficientemente grande a distribuição das médias amostrais será aproximadamente normalmente distribuídas, ou seja:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

TEMA 4 – DISTRIBUIÇÃO AMOSTRAL DE UMA VARIÁVEL ALEATÓRIA BINOMIAL

Em vários modelos teremos uma variável aleatória binomial, que só pode assumir um entre dois possíveis valores: sim ou não, desligado ou ligado, forte ou fraco, 0 ou 1, etc. Nesse caso, o Teorema Central do Limite permite concluir a distribuição amostral dessa variável; trata-se de uma distribuição normal.

4.1 Distribuição amostral

No caso da distribuição binomial, suponhamos um experimento em que desejamos conhecer a proporção de adultos com idade inferior a 30 anos e que possuem casa própria. Para essa análise, definiremos a variável aleatória $\bar{X}$, que registra essa informação. Note que se trata de uma variável binomial, visto que pode assumir apenas dois valores, i.e.,

$$X = \begin{cases} 1, & \text{se o indivíduo possui casa própria} \\ 0, & \text{se o indivíduo não possui casa própria} \end{cases}$$

Como tal variável possui uma distribuição de Bernoulli, percebemos que

$$\mu = E(X) = p$$

$$\sigma^2 = Var(X) = p(1 - p)$$

no qual p representa $P(X = 1)$.

Como vimos, não temos condição de obter informação acerca de todos os elementos da população. Assim, devemos realizar uma amostragem aleatória $X_1, X_2, \dots, X_n$ de n termos, sem reposição. Indicando por Y_n o total de indivíduos que possuem casa própria nessa amostra, podemos verificar que

$$Y_n \sim Binomial(n, p),$$

ou seja, Y_n segue uma distribuição de Bernoulli. Sendo assim,

$$P(Y_n = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$



Definindo como $\hat{p}$ a proporção de indivíduos que possuem casa própria, podemos escrever

$$\hat{p} = \frac{Y_n}{n}$$

Assim,

$$P(Y_n = k) = P\left(\frac{Y_n}{n} = \frac{k}{n}\right) = P\left(\hat{p} = \frac{k}{n}\right)$$

o que significa que a distribuição amostral de $\hat{p}$ pode ser obtida da distribuição de Y_n e como $Y_n = X_1 + X_2 + \dots + X_n$, com distribuição de Bernoulli, com média $\mu = p$ e variância $\sigma^2 = p(1 - p)$, podemos escrever

$$Y_n = \sum_{i=1}^n X_i = n \sum_{i=1}^n \frac{X_i}{n} = n\bar{X}$$

Ao utilizarmos o Teorema Central do Limite, podemos concluir que $\bar{X}$ terá distribuição aproximadamente normal, com média p e variância $p(1 - p)/n$, ou seja,

$$\bar{X} \sim N\left(p, \frac{p(1 - p)}{n}\right)$$

E, por consequência,

$$Y_n \sim N(np, np(1 - p))$$

E, observando que $\bar{X} = \hat{p}$, concluímos que, para $n \rightarrow \infty$, a distribuição amostral de p é aproximadamente normal

$$\hat{p} \sim N\left(p, \frac{p(1 - p)}{n}\right)$$

4.2 Estudo de Caso: porcentagem de *pets* que passam dos 10 anos de vida

Imagine que seu filho gostaria de ter um *pet* e você está preocupado se ele passaria dos 10 anos de vida. Como você não tem condições suficientes de identificar o tempo de vida de cada um dos elementos (animais) dessa população, deseja estimar a porcentagem baseado num pequeno conjunto de dados. Suponha que tenha os seguintes dados obtidos de 10 animais:

$$X = \begin{cases} 1, & \text{se o pet passa dos 10 anos de vida} \\ 0, & \text{se o pet não passa dos 10 anos de vida} \end{cases}$$



$$X_1 = 1$$

$$X_6 = 0$$

$$X_2 = 0$$

$$X_7 = 0$$

$$X_3 = 0$$

$$X_8 = 0$$

$$X_4 = 0$$

$$X_9 = 0$$

$$X_5 = 1$$

$$X_{10} = 1$$

Assim, podemos notar que entre os *pets* analisados, os únicos que viveram mais de 10 anos foram aqueles observados em X_1, X_5 e X_{10} . Veja que a quantidade de sobreviventes nesse modelo é dada por

$$\sum_{i=1}^n X_i = 1 + 0 + 0 + 0 + 1 + 0 + 0 + 0 + 0 + 1 = 3$$

Já a probabilidade estimada de que um pet sobreviva mais de 10 anos é dada por

$$\hat{p} = \frac{3}{10} = 0,3.$$

Sabendo que trata-se de uma distribuição binomial, caso conhecêssemos a priori a probabilidade real p de sobrevivência, poderíamos calcular a probabilidade de obter $\hat{p} = 0,3$ para uma amostra de tamanho $n = 10$. Veja que nesse caso,

$$p(3) = \binom{10}{3} p^3 (1-p)^7$$

Assim, se a probabilidade real for $p = 0,4$, então $p(3) = 0,215$ indicando que nessa distribuição existe chance de 21,5% de a amostra coletada apresentar $\hat{p} = 0,3$. Para prosseguirmos, imagine que 1.000 pais estão com a mesma preocupação e resolvem, de forma independente, realizar a mesma pesquisa. Nesse cenário, suponha que a população tenha proporção de sobrevivência real dada por $p = 0,3$.

Agora, cada pai pesquisador observará em sua amostra de 10 *pets* um resultado diferente. O primeiro pai poderá observar $\hat{p} = 0,5$, o segundo observará $\hat{p} = 0,2$ e assim por diante. A Tabela 1 apresenta a distribuição de $\hat{p}$ encontrada por cada pesquisador.



Tabela 1 – Proporção de *pets* sobreviventes além dos 10 anos de idade encontrada por diversos pais pesquisadores


$\hat{p}$	n	$\hat{p}$	n
0	29	0,6	41
0,1	122	0,7	7
0,2	240	0,8	1
0,3	253	0,9	0
0,4	200	1	0
0,5	107		

Fonte: Elaborada pelo autor.

Veja que quando desenhamos o gráfico dessa distribuição, encontramos uma distribuição aproximadamente normal, validando o resultado do Teorema Central do Limite.

Veja que o gráfico da Figura 4 apresenta a proporção de *pets* sobreviventes contra a quantidade de respectivos pais pesquisadores que encontraram cada uma dessas proporções. Note, novamente, que essa se aproxima de uma distribuição normal em torno de $p = 0,3$ quando realizamos uma grande quantidade de experimentos. Note, também, que para $n = 1000$, $E(\hat{p}) = 0,299$ e $Var(\hat{p}) = 0,02125124$, o que reforça que $E(\hat{p}) = E(\bar{X}) = \mu$, no qual μ representa a média populacional, para o caso de $n \rightarrow \infty$. Lembre-se que, sabendo que a população possui uma distribuição de Bernoulli, sabemos que $E(\bar{X}) = p = 0,3$ e $Var(X) = p(1 - p) = 0,3 \cdot 0,7 = 0,21$.

Figura 4 – Gráfico apresentando a proporção de *pets* sobreviventes contra a quantidade de pais pesquisadores que encontraram essas proporções



TEMA 5 – DISTRIBUIÇÃO AMOSTRAL DE DADOS NORMAIS

No caso em que os dados são descritos de forma contínua e possuem distribuição normal com média μ e variância σ^2 , verificaremos o que ocorre com uma amostra aleatória

$$X_1, X_2, \dots, X_n,$$



concluindo que ela também se comporta como uma distribuição normal com média μ e variância σ^2/n , ou seja:

$$X_1, X_2, \dots, X_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

5.1 Estudo de caso: tempo para atingir o nível aceitável de corpos cetônicos

Entre as dietas para emagrecimento mais famosas, podemos citar a dieta cetogênica, que pela alimentação tem o objetivo de aumentar o nível de corpos cetônicos no sangue. Esses são responsáveis pela quebra de gordura no organismo e aumentam, significativamente, após determinada quantidade de horas em jejum.

Suponha que um pesquisador deseje saber qual é o tempo, em horas, para atingir o nível de corpos cetônicos aceitável para essa dieta. Imagine que esse teste é realizado em 20 indivíduos encontrando a média amostral $\bar{X} = 8,2$ horas. Note que se essa pesquisa fosse realizada com outros 20 indivíduos, poderíamos encontrar $\bar{X} = 13,3$ horas; repetindo o estudo encontraríamos $\bar{X} = 2,6$ horas e assim por diante. Assim, cada pesquisa realizada encontra uma variação entre as médias amostrais. Para encontrarmos o valor real de $\bar{X}$ deveríamos realizar essa pesquisa infinitas vezes, o que é inviável.

Então, vejamos uma possível simulação de cenário para esse experimento. Vamos considerar uma população normalmente distribuída que possui $\mu = 10 h$ e variância $\sigma^2 = 4$. A Tabela 2 apresenta a quantidade de horas que cada um dos 20 indivíduos das 15 amostras demorou para atingir o nível de corpos cetônicos aceitável em jejum.

Tabela 2 – Dados sobre a quantidade de horas para os 20 indivíduos de cada 15 amostras atingirem o nível de corpos cetônicos aceitável

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
7,98	10,70	7,41	9,92	9,62	8,44	14,46	5,59	7,56	8,66	9,67	11,40	12,18	12,79	12,06
15,16	10,22	9,78	11,82	9,39	5,89	8,40	12,13	13,72	12,42	10,69	8,11	10,25	7,58	7,84
8,13	14,30	6,69	10,01	9,90	11,73	11,92	8,77	10,98	10,24	6,41	8,68	9,98	8,30	12,23
9,84	7,92	12,55	8,91	7,50	10,43	12,99	11,22	7,52	8,50	8,73	9,73	9,49	7,87	7,97
9,15	8,38	9,52	10,39	13,63	8,63	9,08	12,17	10,80	8,18	8,32	12,70	8,95	6,12	12,52
10,80	12,36	11,31	8,12	12,25	12,60	8,11	14,41	9,86	8,37	11,48	8,42	11,48	10,12	12,69
7,43	11,07	8,71	14,06	11,58	10,06	10,58	6,65	13,21	10,29	13,65	10,75	10,70	12,98	11,36
10,61	10,80	9,09	8,85	12,93	13,86	10,66	11,76	11,12	7,77	11,70	10,38	12,89	11,00	10,05
9,64	11,67	8,35	9,51	7,49	8,63	12,22	10,91	11,07	6,99	9,08	9,90	10,08	9,85	9,24



10,44	8,90	7,72	5,10	9,56	8,47	15,78	11,45	7,38	10,21	8,23	14,34	7,78	12,31	10,63
10,98	9,64	11,61	11,80	7,37	8,68	12,53	9,68	10,63	9,64	8,18	8,86	11,11	8,58	9,70
9,96	9,90	8,89	10,94	12,49	9,40	10,97	6,13	9,64	12,93	9,90	13,17	10,26	9,23	11,43
9,50	10,93	9,46	6,09	10,90	9,74	11,93	12,13	10,71	8,58	9,40	12,05	10,75	12,86	10,48
15,30	10,58	10,74	8,12	5,91	9,35	5,27	10,22	12,22	9,82	12,24	8,97	12,54	8,71	11,28
8,13	8,81	10,72	7,52	11,86	7,74	12,53	7,42	10,38	10,28	11,27	8,85	11,19	6,11	8,98
9,47	11,46	9,05	9,22	10,06	12,46	6,89	9,95	12,54	6,86	7,70	12,55	11,66	7,50	11,52
9,14	9,02	11,98	8,52	6,42	7,24	10,04	5,79	9,64	9,57	9,66	10,03	9,36	11,80	9,88
11,47	13,56	9,26	8,19	9,09	8,83	10,18	9,60	8,77	9,23	8,50	12,21	8,09	10,67	11,68
9,65	8,11	10,08	10,85	7,99	12,46	10,30	8,58	9,84	13,98	10,64	8,72	8,78	12,22	9,96
12,67	8,96	8,43	10,53	10,52	10,18	8,49	11,05	10,27	7,32	9,28	10,14	12,20	7,51	9,59

Com base nesses dados foi possível gerar as médias amostrais, obtendo os dados que estão contidos na Tabela 3.


Tabela 3 – Médias amostrais do tempo para o nível de corpos cetônicos no sangue atinjam um nível aceitável

1	10,27
2	10,37
3	9,57
4	9,42
5	9,82
6	9,74
7	10,67
8	9,78
9	10,39
10	9,49
11	9,74
12	10,50
13	10,49
14	9,74
15	10,55

Com base nessas médias amostrais, podemos desenhar um gráfico representando como essa distribuição está se comportando. Nesse caso, decidimos desenvolver um histograma iniciando em 9.4 com passo de 0.2, que pode ser conferido na Figura 5.




Figura 4 – Histograma apresentando a distribuição das médias amostrais para 15 amostras



Note que esse histograma já começa a apresentar uma distribuição aproximadamente normal para os dados coletados. Quando calculamos a média nesse cenário, encontramos 10,0336 e desvio padrão de 0,435847.

Note também que aumentar a quantidade de amostras faz com que os dados se tornem cada vez mais próximos de uma distribuição normal. A Figura 6 apresenta o histograma gerado para um total de 200 amostras ($n = 200$).

Figura 5 – Histograma desenvolvido para a média amostral dos 20 indivíduos entre as 200 amostras






Nesse caso, o gráfico encontrado está visivelmente mais próximo de uma distribuição normal. Ao calcularmos a média das médias amostrais, encontramos $\mu = 10,02$ e para o desvio padrão $s^2 = 0,48$, o que se aproxima muito do valor real do começo do problema.

Para o mesmo experimento, mas considerando uma quantidade de 10.000 amostras ($n = 10.000$), obtemos o histograma da Figura 7, em que podemos observar que a distribuição está cada vez mais próxima da

$$\begin{aligned} N\left(\mu, \frac{\sigma}{\sqrt{n}}\right) &= \\ N\left(10, \frac{2}{\sqrt{20}}\right) &= \\ N(10; 0,4472) \end{aligned}$$

Tanto que, ao calcular sua média amostral e seu desvio padrão, encontramos $\mu = 9,9993$ e $s^2 = 0,4500$. Vale reforçar que esse resultado se deve ao Teorema Central do Limite, mostrando que as médias amostrais para uma quantidade de amostras, $n \rightarrow \infty$, tende à média populacional.

Figura 6 – Histograma desenvolvido para a média amostral dos 20 indivíduos entre as 10.000 amostras





5.2 Distribuição qui-quadrado

No caso da estatística s^2 , podemos encontrar a sua distribuição. Essa é chamada de qui-quadrado e representa um estimador não viciado da variância σ^2 . Dada a função densidade de probabilidade,

$$f_X(x) = \frac{1}{\Gamma\left(\frac{k}{2}\right)} \left(\frac{1}{2}\right)^{\frac{k}{2}} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} \Pi_{(0, \infty)}(x)$$

para uma variável aleatória X , dizemos que X tem uma distribuição qui-quadrado com $k \in \mathbb{N}$ graus de liberdade. Para as variáveis aleatórias $X_1, X_2, \dots, X_n$ independentes e normalmente distribuídas, com médias μ_i e variância σ_i^2 , verificamos que

$$U = \sum_{i=1}^n \left(\frac{X_i - \mu_i}{\sigma_i} \right)^2$$

possui uma distribuição qui-quadrado com n graus de liberdade.

Além disso, sendo $X_1, X_2, \dots, X_n$ uma amostra aleatória com distribuição normal padrão, podemos afirmar que $\bar{X}$ e $\sum_{i=1}^n (X_i - \bar{X})^2$ são independentes e $\sum_{i=1}^n (X_i - \bar{X})^2$ tem uma distribuição qui-quadrado com $n - 1$ graus de liberdade. Disso, extrai-se que se s^2 representa a variância amostral de uma amostra $X_1, X_2, \dots, X_n$ aleatória que possui uma distribuição normal de média μ e variância σ^2 , então

$$U = \frac{(n-1)s^2}{\sigma^2}$$

também tem uma distribuição qui-quadrado com $n - 1$ graus de liberdade.

Para analisar esse resultado, vamos revisitar a Tabela 2, que apresenta dados dos 20 indivíduos de cada uma das 15 amostras sobre a quantidade horas necessária para o nível de corpos cetônicos fique aceitável. Agora, ao invés de calcular a média das amostras, a Tabela 4 apresenta o resultado do cálculo da variância do tempo para que o nível dos corpos cetônicos no sangue atinjam um nível aceitável para cada uma das amostras.




Tabela 4 – Variâncias amostrais do tempo para o nível de corpos cetônicos no sangue atinjam um nível aceitável

1	10,27
2	10,37
3	9,57
4	9,42
5	9,82
6	9,74
7	10,67
8	9,78
9	10,39
10	9,49
11	9,74
12	10,50
13	10,49
14	9,74
15	10,55


A Figura 8 apresenta essa mesma informação na forma de um histograma. Ao calcular a média das variâncias nesse cenário encontramos 3,864 e a variância das variâncias de 1,817. À medida que aumentamos a quantidade de amostras, essa distribuição vai se aproximando da distribuição qui-quadrado.

Figura 7 – Histograma das variâncias das 15 amostras analisadas




A Figura 9 apresenta esse mesmo modelo redesenhado para um tamanho de amostra de 1.000 elementos ($n = 1.000$). Ao calcular a média das variâncias é 4,006 e a variância é 1,694.

Figura 9 – Histograma das variâncias das 1.000 amostras analisadas



Lembre-se que o Teorema Central do Limite afirma que a distribuição amostral tende à determinada distribuição à medida que $n \rightarrow \infty$. Isso pode ser verificado ao analisar a Figura 10, que apresenta o histograma das variâncias para 10.000 amostras ($n = 10.000$). Nesse caso, a média das variâncias é 4,026, e que a variância é de 1,673 – muito próximo da variância populacional! Isso pode ser confirmado, pois nessa população de análise, a distribuição é do tipo qui-quadrado com média $\mu = 4$ e variância $\frac{2\sigma^4}{n-1} = \frac{2 \times 16}{19} = 1,684$.

Figura 8 – Histograma das variâncias das 10.000 amostras analisadas





FINALIZANDO

Finalmente, conseguimos discutir os primeiros resultados necessários à compreensão da Modelagem Estatística. Como nosso objetivo é realizar a análise de duas importantes classes de métodos estatísticos, ANOVA e regressão linear serão necessários para entender os tipos de distribuição a fim de estimarmos os parâmetros do modelo.

A distribuição binomial e a distribuição normal não são as únicas existentes nesse ramo, mas à medida que as outras distribuições forem necessárias serão citadas ao longo do material.



REFERÊNCIAS

LARSON, R.; FARBER, B. **Estatística aplicada**. 6 ed. São Paulo: Pearson Education do Brasil, 2015.

CASTANHEIRA, N. P. **Estatística aplicada a todos os níveis**. Curitiba: InterSaberes, 2012.

CASTANHEIRA, N. P. **Métodos Quantitativos**. Curitiba: InterSaberes, 2013.

MONTGOMERY, D. C.; RUNGER, G. C. **Estatística aplicada e probabilidade para engenheiros**. 5 ed. Rio de Janeiro: LTC, 2012.

SIQUEIRA, J. O. **Fundamentos de Métodos Quantitativos**. São Paulo: Saraiva, 2011.

DOWNING, D.; CLARK, J. **Estatística aplicada**. 3 ed. São Paulo: Saraiva, 2010.

MONTGOMERY, D. C.; RUNGER, G. C.; HUBELE, N. F. **Estatística aplicada à engenharia**. 2 ed. Rio de Janeiro: LTC, 2013.

FREUND, J. E. **Estatística aplicada**. 11 ed. Porto Alegre: Bookman, 2007.