



MODELAGEM ESTATÍSTICA

AULA 4



Os métodos de regressão linear buscam determinar uma função que melhor descreve um determinado conjunto de dados que podem se comportar, aproximadamente, como uma reta, i.e., linear.


A Figura 1 apresenta o tipo de modelo investigado. Aqui, gostaríamos de encontrar como a variável independente y_i está associada aos possíveis valores que a variável dependente x_i assume.

Para analisarmos esse cenário, suponha que você seja um cientista preocupado em verificar características de uma determinada mola. Como sabe que toda mola atende às exigências da *Lei de Hook*, qual seja:

$$F = -k.\Delta X,$$

então pretende coletar dados para encontrar o coeficiente de elasticidade, k . Vejamos o tipo de análise que você deve realizar.

Figura 1 – Regressão linear



Fonte: Recologia, 2012.



TEMA 1 – REGRESSÃO LINEAR SIMPLES

No primeiro cenário de regressão que iremos considerar, analisaremos o caso linear simples. Nesse caso, uma única variável de controle (independente), x altera o resultado de uma única variável de saída (dependente), y .

1.1 Modelo Estatístico

Para o tipo de análise que desejamos realizar, é necessário coletar um conjunto de dados relacionando as duas variáveis. Nesse caso, consideramos n pares de medidas e as denotamos por:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

As quais podem ser descritas a partir de uma Tabela. No exemplo que iremos discutir nessa aula, consideramos os dados descritos na Tabela 1.

Tabela 1 – Forças necessárias para causar deslocamento

Observação	Δx (cm)	F (N)
1	220	122
2	220	119
3	220	122
4	220	122
5	220	122
6	225	126
7	225	129
8	225	126
9	225	124
10	225	128


Observação	Δx (cm)	F (N)
11	230	133
12	230	133
13	230	132
14	230	133
15	230	135
16	235	135
17	235	136
18	235	137
19	235	137
20	235	137

Nessa tabela, realizamos um experimento com determinada mola a esticando por 220, 225, 230 ou 235 cm e medindo a força necessária para realizar tal deslocamento. Como as medidas foram realizadas em momentos diferentes, obtemos valores que possuem uma determinada variabilidade devido ao comportamento de fatores que não controlamos no experimento. A título de exemplo, utilizamos o Excel para traçar o gráfico dos dados do problema na



Figura 2. Note que a variável independente é o deslocamento, enquanto a variável dependente é a força.

Figura 2 – Deslocamento versus força



Note também que o gráfico já nos permite observar que os dados se comportam, aproximadamente, como uma reta, indicando o caso de análise da regressão linear simples.

Para os pares de dados (x_i, y_i) , o modelo estatístico de regressão linear simples é dado por:

$$y = \alpha + \beta \cdot x + \epsilon_i, i = 1, \dots, n$$

Note que trata-se de uma equação de reta, em que β representa o coeficiente angular (i.e. a inclinação da reta), α o coeficiente linear e ϵ_i o erro obtido gerado pela aleatoriedade e por não considerar outros efeitos na explicação da variável de interesse.

No modelo considerado, supomos que a relação entre as duas variáveis y_i e x_i são lineares. Entretanto, nem sempre essa é uma assertiva verdadeira, de forma que, ao final da análise, verificaremos a importância do coeficiente de determinação para adequar a confiabilidade do modelo. Além disso, supomos que as variáveis não são aleatórias, visto que possuímos um controle (i.e., um planejamento do experimento) dos dados selecionados. Também supomos que as médias dos erros são nulos, de forma que $y = \alpha + \beta \cdot x$.

1.2 Estimação dos Parâmetros do Modelo

Devemos considerar uma estratégia para determinar a melhor reta que descreve o conjunto de pontos analisado. Na regressão que iremos desenvolver,



consideramos utilizar a reta que minimiza o quadrado dos erros, de forma que costumamos denominar a regressão linear como pertencente à classe de **Métodos dos Mínimos Quadrados**.

Para compreender a minimização do erro, considere o cálculo do erro ao escolhermos um dos possíveis valores que α e β podem assumir. Para o conjunto de dados, (x_i, y_i) , temos que:

$$\epsilon_i = y_i - (\alpha + \beta \cdot x_i).$$

Como y_i representa o valor observado e $\alpha + \beta \cdot x_i$ representa o valor estimado pela regressão, verificamos que ϵ_i representa quão afastado a estimativa está do valor observado (i.e., medido).

Considerando a soma do quadrado do erro ϵ_i dado por SQE :

$$SQE = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n [y_i - (\alpha + \beta \cdot x_i)]^2$$

e considerando que desejamos encontrar os valores de α e β que minimizam SQE , então encontramos os pontos críticos, fazendo:

$$\begin{cases} \frac{\partial}{\partial \alpha} SQE = 0 \\ \frac{\partial}{\partial \beta} SQE = 0 \end{cases}$$

O que nos leva a (pelo uso da regra de derivação – regra da cadeia):

$$\begin{cases} -2 \cdot \sum_{i=1}^n [y_i - (\alpha + \beta \cdot x_i)] = 0 \\ 2 \cdot \sum_{i=1}^n [y_i - (\alpha + \beta \cdot x_i)] \cdot x_i = 0 \end{cases} \quad \therefore \quad \begin{cases} \sum_{i=1}^n [y_i - (\alpha + \beta \cdot x_i)] = 0 \\ \sum_{i=1}^n [y_i - (\alpha + \beta \cdot x_i)] \cdot x_i = 0 \end{cases} \quad \therefore$$

$$\begin{cases} \sum_{i=1}^n y_i = \sum_{i=1}^n [\alpha + \beta \cdot x_i] \\ \sum_{i=1}^n y_i x_i = \sum_{i=1}^n [(\alpha + \beta \cdot x_i) \cdot x_i] \end{cases}$$

Essas equações podem ser simplificadas se considerarmos as médias das observações, i.e.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Assim, reescrevemos:



$$\begin{cases} \sum_{i=1}^n y_i = n\alpha + \beta \cdot \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i y_i = \alpha \cdot \sum_{i=1}^n x_i + \beta \cdot \sum_{i=1}^n x_i^2 \end{cases}$$

Isolando α na primeira equação e substituindo na segunda obtemos:

$$\alpha = \frac{1}{n} \left[\sum_{i=1}^n y_i - \beta \cdot \sum_{i=1}^n x_i \right]$$

$$\sum_{i=1}^n x_i y_i = \frac{1}{n} \left[\sum_{i=1}^n y_i - \beta \cdot \sum_{i=1}^n x_i \right] \cdot \sum_{i=1}^n x_i + \beta \cdot \sum_{i=1}^n x_i^2$$

Multiplicando por n :

$$n \cdot \sum_{i=1}^n x_i y_i = \left[\sum_{i=1}^n y_i - \beta \cdot \sum_{i=1}^n x_i \right] \cdot \sum_{i=1}^n x_i + \beta n \cdot \sum_{i=1}^n x_i^2$$

Assim,

$$\beta = \frac{n \cdot \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$

Substituindo este termo, podemos encontrar o parâmetro α :

$$\alpha = \frac{1}{n} \left[\sum_{i=1}^n y_i - \beta \cdot \sum_{i=1}^n x_i \right] =$$

$$\frac{1}{n} \left[\sum_{i=1}^n y_i - \left[\frac{n \cdot \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \right] \cdot \sum_{i=1}^n x_i \right]$$

Entretanto, é mais recomendável utilizar o próprio modelo de regressão para encontrar o cálculo de α . Como:

$$\hat{y} = \alpha + \beta \hat{x}$$

$$\alpha = \bar{y} - \beta \bar{x}$$

Para facilitar os cálculos necessários, utilizamos uma tabela de auxílio para os cálculos manuais, como a generalizada na Tabela 2.



Tabela 2 – Auxílio para cálculos manuais

n_i	x_i	y_i	$x_i \cdot y_i$	x_i^2
1	x_1	y_1	$x_1 y_1$	x_1^2
2	x_2	y_2	$x_2 y_2$	x_2^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_n	y_n	$x_n y_n$	x_n^2
Σ	$\sum_{i=1}^n x_i$	$\sum_{i=1}^n y_i$	$\sum_{i=1}^n x_i y_i$	$\sum_{i=1}^n x_i^2$

1.3 Exemplo

No exemplo que estamos analisando ao longo da aula, vamos determinar os coeficientes α e β para o modelo que relaciona força e deslocamento:

$$F = \alpha + \beta \cdot \Delta x$$

Como temos como suposição que tal experimento atende à Lei de Hooke (i.e., $F = -k \cdot \Delta x$), caso os dados do experimento se comportem como uma reta, poderemos afirmar que o coeficiente de elasticidade, k , será determinado por β . Como precisamos determinar alguns somatórios, utilizaremos a Tabela 3 para auxiliar nos cálculos manuais. Nela, consideramos F como y e Δx como x para facilitar o reconhecimento dos termos calculados necessários.

Tabela 3 – Auxílio para cálculos manuais

n_i	x_i	y_i	$x_i \cdot y_i$	x_i^2
1	220	122	26.840	48.400
2	220	119	26.180	48.400
3	220	122	26.840	48.400
4	220	122	26.840	48.400
5	220	122	26.840	48.400
6	225	126	28.350	50.625
7	225	129	29.025	50.625
8	225	126	28.350	50.625
9	225	124	27.900	50.625
10	225	128	28.800	50.625



11	230	133	30.590	52.900
12	230	133	30.590	52.900
13	230	132	30.360	52.900
14	230	133	30.590	52.900
15	230	135	31.050	52.900
16	235	135	31.725	55.225
17	235	136	31.960	55.225
18	235	137	32.195	55.225
19	235	137	32.195	55.225
20	235	137	32.195	55.225
Σ	4.550	2.588	589.415	1.035.750

Substituindo os dados do problema, obtemos:

$$\beta = \frac{n \cdot \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \cdot \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$
$$\beta = \frac{20 \cdot 589.415 - 4.550 \cdot 2.588}{20 \cdot 1.035.750 - (4.550)^2} = 1,032$$

Como:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{4.550}{20} = 227,5$$
$$\bar{y} = \frac{\sum y_i}{n} = \frac{2.588}{20} = 129,4$$

Então,

$$\bar{y} = \alpha + \beta \bar{x}$$
$$\alpha = \beta \bar{x} - \bar{y} = 105,38$$

Dessa forma, o modelo que descreve a relação da força com o deslocamento é dado por:

$$F = 105,38 + 1,032 \cdot \Delta x$$

Comparando com a Lei de Hooke, $F = k\Delta x$, notamos que o coeficiente de elasticidade é de $1,032 \text{ N/m}$ e que a mola ficará no referencial zero de deslocamento no caso em que estará sujeita a uma força de $105,38 \text{ N}$.



TEMA 2 – INTERVALO DE CONFIANÇA PARA OS PARÂMETROS

Conhecendo propriedades das distribuições dos dados, podemos escrever intervalos de confiança para os valores de α e β .

2.1 Teste de Hipótese para β

Desejamos garantir, com um nível de confiança α' , o seguinte teste de hipótese:

$$\begin{cases} H_0: \beta = 0 \\ H_1: \beta \neq 0 \end{cases}$$

Podemos provar, mas foge ao escopo dessa aula, que os dados seguem uma distribuição t de student e que a estatística de teste é dada por:

$$T_0 = \frac{\beta}{\sqrt{\frac{QME}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

$$QME = \frac{SQE}{n - 2}$$

$$SQE = \sum_{i=1}^n y_i^2 - n\bar{y}^2 - \beta \cdot \left(\sum_{i=1}^n x_i y_i - n \cdot \bar{x} \bar{y} \right)$$

No caso dos dados do problema analisado, note que:

$$SQE = 335.594 - 20 \cdot (129,4)^2 - 1,032 \cdot (589.415 - 20 \cdot 227,5 \cdot 129,4)$$

$$SQE = 41,16$$

$$QME = \frac{41,16}{18} = 2,2867$$

$$T_0 = \frac{1,032}{\sqrt{\frac{2,2867}{625}}} = 17,061$$

O teste que devemos realizar é aceitar H_0 , se $T_0 < t_{(1-\alpha', 2, n-2)}$ e rejeitar H_0 , caso contrário. Como $t_{(0.95, 2, 18)} = 2,101$, podemos rejeitar a hipótese H_0 .

2.2 Intervalo de Confiança para β

Podemos provar, mas também foge ao escopo dessa aula, que o intervalo de confiança para o parâmetro β é dado por:



$$\beta - t_{(1-\frac{\alpha}{2}, n-2)} \sqrt{\frac{QME}{\sum_{i=1}^n (x_i - \bar{x})^2}} \leq \beta \leq \beta + t_{(1-\frac{\alpha}{2}, n-2)} \sqrt{\frac{QME}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Assim, para os dados do problema:

$$1,032 - 2,101 \cdot \sqrt{\frac{2,2867}{625}} \leq \beta \leq 1,032 + 2,101 \cdot \sqrt{\frac{2,2867}{625}}$$
$$0,905 \leq \beta \leq 1,159$$

TEMA 3 – ANÁLISE DE VARIÂNCIA

O teste de hipótese realizado anteriormente pode ser feito com o uso da ANOVA com um fator.

3.1 ANOVA com um fator

Para a ANOVA, devemos calcular as somas dos quadrados totais, do fator (regressão) e do erro. SQR terá 1 grau de liberdade, SQT , $n - 1$ graus de liberdade e SQE , $n - 2$ graus de liberdade. A Tabela 4 apresenta a tabela da ANOVA calculada para o cenário do exemplo (detalhes podem ser conferidos em aulas anteriores).

Tabela 4 – Tabela da ANOVA

Variação	<i>SQ</i>	<i>gl</i>	<i>MQ</i>	<i>F</i> ₀
Fator	665,64	1	665,64	291,10
Erro	41,16	18	2,29	
Total	706,80	19		

Lembre-se que o teste de ANOVA pode ser realizado comparando F_0 com $F_{(0.95,1,18)} = 4,4138$.

Nesse caso, podemos rejeitar a hipótese H_0 , visto que $F_0 > F_{(0.95,1,18)}$ (i.e., $291,10 > 4,4138$).

TEMA 4 – COEFICIENTE DE DETERMINAÇÃO

Com o método de regressão linear simples, você sempre será capaz de traçar uma reta que minimiza o quadrado dos erros. Entretanto, alguns dados



não se comportam como uma reta, de forma que o modelo desenvolvido não é adequado para a sua descrição. Avaliamos a qualidade do modelo a partir da análise do coeficiente de determinação.

4.1 Obtenção do Coeficiente de Determinação


Podemos obter o coeficiente de determinação, R^2 , como:

$$R^2 = \frac{SQR}{SQT} = \frac{\beta \sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Outra forma equivalente seria escrever:

$$R^2 = \frac{(\sum_{i=1}^n (x_i - \bar{x}) y_i)^2}{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}$$


Figura 3 – Figura 3: Dados dispersos de forma que $R^2 \rightarrow 0$



Pode-se provar que o valor de R^2 está contido entre 0 e 1. Alguns livros utilizam chamam de *coeficiente de determinação* o termo R , tal que $-1 \leq R \leq 1$; entretanto, utilizar R^2 , tal que $0 \leq R^2 \leq 1$ facilita a análise ao evitar operar com números negativos. Dessa forma, podemos afirmar que quanto mais $R^2 \rightarrow 1$ (vide Figura 4), mais forte é o poder explicativo do modelo linear. Quanto mais $R^2 \rightarrow 0$ (vide Figura 3), menos podemos confiar no modelo, visto que os dados não se aproximam de uma reta.



Figura 4 – Dados dispersos de forma que $R^2 \rightarrow 0$



4.2 Exemplo

Para os dados do exemplo, podemos calcular o coeficiente de determinação:

$$R^2 = \frac{(\sum_{i=1}^n (x_i - \bar{x})y_i)^2}{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2} = \frac{(645)^2}{625 \cdot 706,8} = 0,9417$$

O que nos indica que os dados se comportam, aproximadamente, de forma linear. Note que esse já era o resultado esperado quando nos confrontamos com a Figura 2 apresentada no início da aula.

TEMA 5 – LINEARIZAÇÃO DE DADOS

Alguns dados que tratamos não provêm de um comportamento linear, mas podem, com um determinado ajuste, se comportar de tal forma. Para isso, realizamos um ajuste chamado de *linearização dos dados*.

5.1 Linearização do tipo $y = ax^2$

No caso que discutimos ao longo da aula, o modelo físico envolvido se expressa por uma equação linear (i.e., pela Lei de Hooke). Entretanto, alguns modelos são do tipo $y = ax^2$. Podemos citar, por exemplo, o modelo de um objeto, partindo do repouso, em queda livre no vácuo, cuja equação é dada por:



$$y = y_0 + \frac{at^2}{2}$$

Nesses casos, coletar dados (t_i, y_i) nos apresentarão dados com comportamento parabólicos, de forma que o coeficiente de determinação será próximo de 0. Podemos contornar essa dificuldade, realizando uma mudança de variável. Nesse caso, poderíamos coletar dados do tipo (t_i^2, y_i) e o modelo se comportaria como uma reta.

Assim, a linearização nesse caso se comporta como uma mudança de variável em que $t = x^2$ e, portanto, $y = at$.

5.2 Linearização do tipo $y = a \cdot x^\alpha$

No caso em que o modelo é do tipo $y = a \cdot x^\alpha$, podemos coletar dados de forma que o experimento analisado se apresente de forma linear. Para isso, é necessário notar que sendo $y = a \cdot x^\alpha$, então:

$$\ln y = \ln a \cdot x^\alpha$$

$$\ln y = \ln a + \alpha \cdot \ln x$$

Dessa forma, devemos coletar dados do tipo $(\ln x_i, \ln y)$ e o modelo se comportará como uma reta. Note que, plotando os dados dessa forma, $\ln a$ representa o coeficiente linear e α representa o coeficiente angular no modelo, respectivamente.

5.3 Linearização do tipo $y = \frac{a}{x}$

No caso em que o modelo é do tipo $y = \frac{a}{x}$, basta realizar uma mudança de variáveis para que se comporte como uma reta. Nesse caso, chamamos $t = \frac{1}{x}$ e, portanto, $y = at$. Note que os dados que precisam ser coletados nesse cenário são da forma $(\frac{1}{x_i}, y_i)$.

5.4 Linearização do tipo $y = a\sqrt{x}$

No caso em que o modelo é do tipo $y = a\sqrt{x}$, basta realizar uma mudança de variáveis de forma que $t = \sqrt{x}$. Nesse caso, também temos $y = at$. Entretanto, os dados coletados precisam ser da forma $(\sqrt{x_i}, y_i)$.



5.5 Linearização do tipo $y = a \cdot e^{bx}$

No caso em que $y = a \cdot e^{bx}$, devemos verificar que:

$$\ln y = \ln a \cdot e^{bx}$$

$$\ln y = \ln a + \ln e^{bx}$$

$$\ln y = \ln a + bx$$

De forma que o modelo linearizado se comporta como uma reta cujo coeficiente linear é $\ln a$ e coeficiente angular é b . Nesse caso, devemos coletar dados da forma $(x_i, \ln y_i)$.

FINALIZANDO

Nesta aula, aprendemos sobre a técnica de regressão linear simples que busca minimizar o quadrado dos erros para encontrar a melhor reta que descreve os pontos pesquisados. Veremos outras formas de realizar regressões a partir da aula seguinte.



REFERÊNCIAS

CASTANHEIRA, N. P. **Estatística aplicada a todos os níveis**. Curitiba: InterSaberes, 2012.

CASTANHEIRA, N. P. **Métodos Quantitativos**. Curitiba: InterSaberes, 2013.

DOWNING, D.; CLARK, J.; **Estatística aplicada**. 3. ed. São Paulo: Saraiva, 2010.

FREUND, J. E. **Estatística aplicada**. 11. ed. Porto Alegre: Bookman, 2007.

LARSON, R.; FARBER, B. **Estatística aplicada**. 6. ed. São Paulo: Pearson Education do Brasil, 2015.

MONTGOMERY, D. C.; RUNGER, G. C.; HUBELE, N. F. **Estatística aplicada à engenharia**. 2. ed. Rio de Janeiro: LTC, 2013.

MONTGOMERY, D. C.; RUNGER, G. C. **Estatística aplicada e probabilidade para engenheiros**. 5. ed. Rio de Janeiro: LTC, 2012.

SIQUEIRA, J. O. **Fundamentos de Métodos Quantitativos**. São Paulo: Saraiva, 2011.