



REINFORCEMENT LEARNING

AULA 2



Prof. Gian Carlo Brustolin



CONVERSA INICIAL

Neste estudo sobre reinforcement learning (RL), ou aprendizagem por reforço (AR), em português, enfrentaremos alguns problemas relativamente novos para a engenharia da computação. Os primeiros estudos para a aplicação dessa técnica de aprendizado de sistemas de IA datam do final da primeira década deste milênio. Porém, a eficiência dos algoritmos existentes, como veremos, era insuficiente para que a técnica fosse eficaz na solução dos problemas a que se propunha.

O aprendizado de máquina, até o surgimento da AR, sedimentou-se em metodologias supervisionada e auto-organizada (não supervisionada). No primeiro caso, uma amostra da realidade de operação com resultados conhecidos era usada para treinar o sistema de IA. No segundo, o sistema autotransferia as entradas, a partir de uma seleção amostral estatística. Esses métodos, como já comentamos, se mostraram ineficientes para o enfrentamento de problemas em ambientes estocásticos e de decisão sequencial.

A exigência de adaptabilidade do agente, operando em ambientes com constante mutação, não pode ser resolvida pelo paradigma clássico da generalização do aprendizado. Como o ambiente muda, os parâmetros do sistema também mudam, invalidando o treinamento a partir de dado ponto. É o exemplo clássico do robô treinado para andar em um ambiente: se o ambiente muda radicalmente, o treinamento será incapaz de guiá-lo pelo novo mundo. Será necessário que a máquina se adapte. Este é o campo da aprendizagem por reforço.

Considerando que o algoritmo ótimo de RL ainda aguarda solução definitiva, podemos esperar uma série de certezas tênues, ou ainda incertezas, no que se refere a técnicas de treinamento e principalmente de aceleração do treinamento por RL. Por esse motivo, vamos reforçar o estudo de alguns padrões de base já consolidados, buscando sustentação teórica para o entendimento de protocolos ainda em fase de implementação.

Trata-se de um estudo um tanto robusto, de modo que necessitaremos do apoio de conhecimentos prévios de IA, como machine learning e teoria do aprendizado. Assim, convidamos todos os leitores a revisar esses temas e a



acompanhar os presentes estudos com um mergulho na literatura recomendada ao final de cada etapa.

Ao final desta caminhada, você terá uma visão sólida de treinamento por reforço em sistemas de IA e das alternativas mais promissoras de RL. Passamos então ao início desse empolgante estudo.

Nesta etapa, vamos abordar então, a primeira parte da teoria de base de RL. Iniciaremos com um aprofundamento sobre o processo de decisão de Markov. Para entender a ideia de MDP, entretanto, é necessário o entendimento de redes bayesianas, o que por sua vez exige certo conhecimento do cálculo de probabilidades. Assim, iniciaremos nosso estudo com uma breve revisão do tema de probabilidade, com foco em IA.

TEMA 1 – CONCEITOS DE PROBABILIDADE

A ideia de calcular probabilidades remonta aos primeiros calculistas humanos, como resposta ao desejo de entender os fenômenos, conferindo a certa previsibilidade, mesmo que parcial. Sabemos que, na maioria dos eventos cotidianos, não existem certezas absolutas, especialmente sobre o futuro. De qualquer forma, mesmo na ausência de certezas, podemos formular hipóteses com o uso dos dados disponíveis.

Para a revisão que segue, tomaremos por base o que nos ensina Coppin (2010, p. 284 e seguintes). Outra obra interessante para o estudo do tema é o livro de Ross (2010).

Inicialmente, devemos conceituar o espaço de eventos ou o espaço de amostras como a totalidade dos eventos possíveis para uma dada situação. Vamos supor um jogo de dados, em que o espaço de eventos é composto por seis elementos. Considerando todas as possibilidades, temos $S=\{1,2,3,4,5,6\}$. O número de elementos de S será grafado como $n(S)$, sendo igual a 6, ou $n(S)=6$.

Um evento será um extrato desse espaço, como a ocorrência de números pares, $E=\{2,4,6\}$. O número de elementos de E será grafado $n(E)$, sendo igual a 3, ou $n(E)=3$.

A probabilidade da ocorrência de um evento envolve o número de elementos do conjunto do evento, dividido pelo número total de elementos do espaço de eventos. Em nosso exemplo, se desejarmos calcular a probabilidade de ocorrência de número par ao lançarmos um dado, temos:



$$P(E) = n(E)/n(S) = 3/6 = 0,5$$

Entendido o conceito de probabilidade, vamos supor agora que queremos prever a venda de um produto A em um estabelecimento em um certo dia do mês de setembro. Suponha que essa loja só vende um item por dia. Sabemos que o produto A é vendido em 90% dos dias do mês, enquanto o produto B é vendido em 5% dos dias. Do ponto de vista matemático, esses dados podem ser escritos da seguinte forma:

$$P(A) = 0,90$$

$$P(B) = 0,05$$

A primeira equação nos informa que as chances de vender A é de 0,9. Já na segunda sentença, a probabilidade de não vender A, mas vender B, é de 0,05. Como os valores de probabilidades são números absolutos entre zero e 1, se consideramos $P(A) = 1$, isso significa que venderemos somente o produto A ao longo de todos os dias do mês de setembro.

A notação $P(\tilde{A})$, $P(\sim A)$ ou $P(\neg A)$ indica a probabilidade da não ocorrência de A. Em nosso exemplo, $P(\sim A)$ indicaria a probabilidade de não vendermos o produto A.


Suponha, agora, para entender outras notações, que desejamos expressar a probabilidade de ocorrência do evento A ou B. Uma vez que um evento é um conjunto de ocorrências, escrevemos essa equação com base na teoria dos conjuntos, como a união dos conjuntos de eventos A e B. Escrevemos $P(A \cup B)$. Porém, como são conjuntos, ao criar a união de ambos, se desejamos contar os elementos, devemos pensar que, se existirem elementos comuns, eles serão contados duas vezes. A região de elementos comuns é chamada de interseção dos conjuntos, sendo expressa por $(A \cap B)$. Vamos expressar matematicamente o que definimos até aqui:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Observe a figura a seguir, que ilustra o conceito.



Figura 1 – Eventos e suas intersecções



Fonte: Elaborado com base em Neto, 2006, p. 19.

Na figura, vemos representados os eventos F , E_1 , E_2 ... Como afirmamos anteriormente, ao contar os elementos de $\{E_2 \cup E_3\}$, contamos duas vezes aqueles presentes na área hachurada. Por esse motivo, precisamos retirar a contagem dobrada.

Em nosso exemplo da loja, somente um produto é vendido por dia, de forma que não há região comum entre A e B . Assim $(A \cap B) = \emptyset$ ($\emptyset$ simboliza o conjunto vazio). Nesse caso, podemos escrever $P(A \cap B) = 0$, ou seja, não existe a possibilidade de vender ao mesmo tempo A e B . Os eventos A e B , nessa situação, são mutuamente excludentes.

Vamos voltar ao cálculo de $P(A \cup B) = P(A) + P(B) - 0 = 0,95$. Ou seja, a possibilidade de vender, em qualquer dia de setembro, o produto A ou B , será de 95%.

Resta ainda entender as **probabilidades condicionadas**.

A expressão $P(F|G)$ pode ser lida como “a probabilidade de F , dado G ”. $P(F|G)$ é a expressão matemática da probabilidade condicionada. Nesse caso, a ocorrência do evento F está condicionada pela ocorrência anterior de F . Simplificando, $P(F|G)$ estabelece a probabilidade de que F seja verdadeiro, já que sabemos que G é verdadeiro. $P(F|G)$ segue a seguinte regra:

$$P(F|G) = \frac{P(F \cap G)}{P(G)}$$

Uma outra forma de apresentar probabilidades é por uma tabela de **probabilidades combinadas ou probabilidades conjuntas**. Veja que as probabilidades condicionadas, que acabamos de estudar, não têm o mesmo



conceito de probabilidade combinada ou conjugada. No caso das conjuntas, podemos apresentar o resultado das amostras dos eventos como uma tabela, como a que segue, ou ainda por um grafo, representação que será estudada em nosso segundo tópico.

Tabela 1 – Probabilidade

	A	$\sim A$
B	0,05	0,35
$\sim B$	0,54	0,22

Na tabela, podemos ler que a probabilidade de acontecer A e B é de 0,05, ou $P(A \wedge B) = 0,05$. Também podemos ler que a probabilidade de ocorrência de A, se não ocorre B, ou $P(A \wedge \sim B)$, é 0,54. Mas qual será a probabilidade de ocorrência de A?

Se temos a probabilidade de ocorrência de A e B ao mesmo tempo e a probabilidade de ocorrência de A e não B, então temos $P(A)$ ao somar os dois valores, $P(A) = 0,05 + 0,54 = 0,59$. Da mesma maneira, $P(B) = 0,05 + 0,35 = 0,40$.

Concluimos assim a nossa revisão do tema de probabilidades. Naturalmente, nossa intenção não era esgotar o tema, mas sim oferecer uma base para os nossos estudos nesta etapa.

TEMA 2 – TEOREMA DE BAYES E REDES BAYESIANAS

Considerando o conhecimento sobre probabilidades condicionadas e probabilidade conjuntas, podemos entender o teorema de Bayes e a partir dele as redes bayesianas, que fundamentam o entendimento das cadeias de Markov. Vejamos as conclusões de Bayes.

2.1 Teorema de Bayes

Bayes foi um matemático inglês do século XVIII. Ele estudou a probabilidade de ocorrência de um evento se temos alguma informação anterior sobre o fato. De forma geral, Bayes propôs que a probabilidade inicial de ocorrência de um determinado evento, normalmente chamada de *crença inicial*, pode ser alterada quando novas evidências sobre ele se tornam disponíveis. O



teorema normalmente é expresso da seguinte forma, em que $P(B)$ é a crença inicial e $P(A)$ a nova evidência:

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

O próprio Coppin (2010, p. 287) nos oferece um exemplo que nos auxilia a entender o teorema, a partir de uma situação hipotética de diagnóstico médico para uma pessoa gripada.

Suponha que uma pessoa gripada tem temperatura alta em 80% dos casos. Assim, queremos saber qual a possibilidade de uma pessoa estar gripada se tem temperatura alta. Analise a afirmação anterior: “uma pessoa gripada tem temperatura alta em 80% dos casos”. Ela não permite a conclusão contrária diretamente. Se temos febre, existe uma grande quantidade de diagnósticos para além da gripe. Sabemos também que 1 em 1.000 pessoas apresentam hipertermia, e que 1 em 10.000 pessoas adoecem com gripe.

Vamos usar A para expressar a temperatura alta e B para o estado gripal. Nesse caso, usamos A como evidência que nos ajuda a verificar a hipótese B . A probabilidade de o paciente apresentar temperatura alta por conta de gripe (a chamada *probabilidade a posteriori*) pode ser escrita da seguinte forma:

$$P(A|B) = 0,8$$

Os demais dados são $P(A) = 0,001$, $P(B) = 0,0001$. Assim, a probabilidade de o paciente estar gripado se apresenta hipertermia pode ser calculada pelo teorema de Bayes:

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)} = \frac{0,8 \cdot 0,0001}{0,001} = 0,08$$

Assim, as chances de se ter gripe apenas a partir da evidência de febre é de 8%. Observe que a possibilidade de um paciente estar gripado, originalmente, era de 0,001%, mas a presença de febre eleva essa possibilidade para 8%.

O teorema de Bayes permite concluir que é possível determinar a probabilidade de uma hipótese com base na probabilidade das evidências



disponíveis. Outra conclusão importante é que, no caso de múltiplas evidências, a maior $P(A|B)$ determinará a maior $P(B|A)$.

Por que isso nos parece evidente? O aprendizado bayesiano é um dos métodos mais comuns de tomada de decisão humana. Precisamos, entretanto, entendê-lo a fundo para ensinar a máquina a pensar e decidir.

2.2 Redes bayesianas


A partir do que estudamos, podemos conceituar uma **rede bayesiana de crença**, conforme nos ensina Norvig (2013, p. 447), como um grafo orientado acíclico, com parâmetros numéricos que representam evidências ou hipóteses ligados a cada nó. Segundo o autor, essas redes são capazes de representar qualquer distribuição de **probabilidade conjunta** completamente – eventualmente, de forma bastante concisa.

Vamos imaginar um exemplo de rede bayesiana. Você comprou um carro famoso por apresentar defeito de injeção por combustível adulterado ou filtro de ar sujo. Você sabe que a probabilidade de adquirir combustível adulterado é de 2%, enquanto a chance de o filtro de ar estar sujo é de 0,7%. Lendo o manual, descobriu que há um painel de alarmes abaixo do velocímetro que indica possível falha no sistema de injeção quando o combustível é adulterado ou quando a entrada de ar está fora dos níveis mínimos de oxigênio para a combustão correta. Quando há falha do sistema de injeção, um led vermelho acende no painel, soando um sinal contínuo. Um tempo depois, o sistema de injeção entra em colapso, sem que você tenha recebido alarme.

Consultado o fabricante, você é informado de que o sistema de sensores não é perfeito, pois falha em 1% dos casos de combustível adulterado e em 3% dos casos de filtro de ar sujo. A atuação do sinal sonoro falha em 10% dos casos se a origem for combustível e em 5% dos casos de falta de oxigênio. O led falha em 0,4% dos casos em que é acionado, enquanto o sinal sonoro falha em 0,6% dos casos. A rede bayesiana equivalente está ilustrada na figura.



Figura 2 – Rede bayesiana



2.3 Semântica das redes bayesianas

Em uma rede bayesiana, os nós (do grafo) que antecedem dado nó são chamados *pais* desse nó. No exemplo anterior, para ilustrar, “combustível e “oxigênio” são pais de “alarme”.

Do ponto de vista do cálculo das probabilidades totais, nos parece evidente que a probabilidade de ocorrência de um evento B depende de seus pais, ou pai, A. Podemos escrever $P(B) = P(B|A)$, ou genericamente, como propõe Norvig (2013, p. 449) $P(X_i | \text{Pais}(X_i))$. Aceita essa notação, podemos propor a equação para calcular a probabilidade conjunta total de um evento X da seguinte forma:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(X_i)) .$$

Assim, é possível calcular a probabilidade de ocorrência combinada de qualquer nó pelo produto das probabilidades condicionais anteriores. Naturalmente, esse cálculo, embora possível, pode se tornar complexo em



grafos extensos. Além disso, do ponto de vista de soluções para um problema decisório, esse cálculo pouco nos ajudaria, senão com a predição das possíveis ações de um agente. Markov enfrenta a questão da limitação da cadeia de antecessores (pais), indicando um caminho para uma decisão ótima em ambientes não determinísticos e sequenciais.

TEMA 3 – HIPÓTESE DE MARKOV

Vamos agora retomar ao estudo do processo decisório de Markov (MDP), introduzido anteriormente, para estudá-lo com o detalhamento necessário. Esse aprofundamento se justifica por conta de sua importância basilar para RL, uma vez que a quase totalidade dos problemas enfrentados por algoritmos de RL pode ser matematicamente modelada com o auxílio do processo de Markov.

3.1 Cadeia de eventos de Markov

Quando um agente enfrenta um meio estocástico, não há como tomar decisões sem que certa dose de incerteza esteja presente. Isso ocorre porque, mesmo que toda informação pertinente às decisões passadas esteja disponível no momento da decisão, como o meio muda, a ação poderá ter consequências diversas daquelas históricas.

No entanto, é lógico que as mudanças do meio são gradativas, com certa previsibilidade. Assim, o resultado de uma ação, mesmo no meio estocástico, tende a se aproximar do pretendido, do ponto de vista estatístico.

Markov, ao analisar as redes bayesianas, percebeu que a previsibilidade do resultado da ação futura depende da análise de uma quantidade finita de ações/resultados anteriores – ou seja, o próximo estado do agente pode ser previsto, basicamente, a partir do estado atual ou de um número limitado de estados anteriores (Norwig, 2013, p. 498). Dito de outra forma, o futuro do agente é condicionalmente independente do passado. Assim, Markov propôs uma corrente de eventos como solução para o problema da previsibilidade.

Vamos imaginar que conhecemos a probabilidade de o evento Φ ocorrer após o evento γ . Se observamos o evento γ , podemos prever a ocorrência de Φ de forma independente do que aconteceu anteriormente à chegada ao estado γ .



Do ponto de vista do estudo das probabilidades, imagine um espaço amostral Ω , de forma que $\Omega = \{A, B, C, D, E, F, G\}$, com eventos equiprováveis e independentes. Vamos supor que desejamos descobrir a possibilidade de ocorrência de um evento unitário qualquer nesse espaço amostral – por exemplo, $P(A)$. O cálculo é elementar. Como $n(\Omega) = 7$, então $P(A)$ será $1/7$. Se agora desejamos descobrir $P(B)$ após a ocorrência de A , teremos $P(B|A)$. Como são eventos independentes, temos:


$$P(B|A) = P(B) \cdot P(A), \text{ que neste caso será } 1/49$$

Suponha agora que Ω descreve um conjunto de estados em um grafo, mantidas as mesmas hipóteses anteriores. A probabilidade de transitar ao estado i após alcançar um estado qualquer j , de Ω , será $1/49$, não importa qual estado anteceda j (Haykin, 2011, p. 595).

Vamos a um exemplo mais concreto. Imagine que sabemos que, ao acordar, um bebê chora por comida em 90% dos casos. Se em determinada situação o bebê acorda, a possibilidade de que nos contemple com sons pouco agradáveis será de 90%. E se antes de dormir ele engatinhou pela casa? Isso afeta a probabilidade de choro? Do ponto de vista matemático, não.

Imagine que levantamos uma segunda estatística. Depois de engatinhar por um bom tempo, o bebê caia no sono. Também podemos supor números para a possibilidade de, após chorar, o bebê voltar a caminhar. É possível descrever essas transições de estados por uma rede bayesiana.

Figura 3 – Grafo das probabilidades de transição





Observando o grafo, fica evidente a hipótese de Markov: mesmo que o estado “engatinhando” possa transitar para “dormindo”, a probabilidade de chorar permanece independente do estado anterior a “dormindo”.

Nesse ponto, convém comentar sobre a possibilidade de eventos não independente. No nosso exemplo, o bebê, ao acordar, pode chorar, com $P(C)=90\%$, ou não chorar. Assim, como só existem duas possibilidades, a probabilidade de não chorar será o complemento de $P(C)$, de modo que $P(\sim C)=10\%$, mas isso não invalida a ideia da independência relativa do futuro em relação ao passado e, por outro lado, do vínculo estatístico do estado futuro com o estado presente.

3.2 Ordens do processo de Markov

Já entendemos como Markov desvinculou o passado do futuro mantendo apenas o vínculo do futuro com o presente. É bem verdade que, se analisamos o grafo do bebê com um pouco mais de senso crítico, podemos considerar que o estado “dormindo” foi alcançado em parte porque o pequeno engatinhou bastante e se cansou. Estendendo a nossa análise, a criança só pode entrar no estado “engatinhar” se, em algum momento, foi alimentada – ou, na linguagem de IA, passou pelo estado “mamando”. Definindo de outra forma, a independência do futuro em relação ao passado não é plena. Por esse motivo, a hipótese de Markov propõe a previsibilidade da ação futura em função de uma **quantidade finita de ações/resultados anteriores, e não somente a partir do estado presente.**

Por conta da ênfase na dependência singular do estado atual, entretanto, as transições entre estados, com dependência do passado desprezível, são chamadas de **transições markesianas de primeira ordem**. Evidentemente, se a previsibilidade do próximo estado depende apenas do estado atual e daquele que o antecede, teremos um **processo de Markov de segunda ordem**.

Agora nos perguntamos se, na hipótese de Markov, ressaltou-se um eventual vínculo, limitado, com o passado – assim, por que a cadeia de Markov dá tanta ênfase ao estado atual? Ou, usando o jargão que acabamos de aprender, por que a maioria dos estudos de otimização supõe processos de



Markov de primeira ordem? Podemos resolver essa questão por inferência, voltando ao exemplo do nosso lactente chorão.

É verdade que, se na cadeia de eventos passados não alimentamos o neném, ele terá pouca energia para engatinhar. Porém, se ele já se encontra no estado “engatinhando”, é aceitável que já tenha sido alimentado suficientemente. Assim, o vínculo com o passado não pode ter a mesma intensidade de representação do estado presente. Na maioria dos casos, considerando que o estado que desejamos já foi atingido, podemos desprezar esse vínculo.

Markov tratou a questão da maior ou menor representatividade dos eventos com o conceito de utilidade descontada. Porém, ainda temos que visitar o conceito de recompensa antes de discutir a ideia da utilidade.

TEMA 4 – RECOMPENSAS

O meio é o ambiente externo ao agente. O agente realiza ações no ambiente, movendo-se entre estados. Podemos imaginar que, a cada ação realizada, o agente recebe um feedback do meio, o que chamamos de *recompensa*. A recompensa é um valor numérico qualquer, proporcional à assertividade do resultado em relação ao objetivo da política do agente.

A ideia de recompensa não simula a reação newtoniana do meio a uma ação qualquer, mas tem o condão de indicar ao agente se determinada ação está alinhada com o objetivo de existência no meio. Esse é o motivo pelo qual alguns teóricos entendem a RL como uma técnica de aprendizagem mais próxima da supervisionada do que da auto-organizada. Entretanto, a análise da reação do meio, traduzida na recompensa, não demanda um supervisor. O agente, a partir dos seus sensores, avalia o efeito da ação. Essa avaliação depende do grau de observabilidade do meio, conforme aprendemos anteriormente.

Suponha, no exemplo do bebê chorão, que você oferece uma mamadeira para o lactente, assim que ele desperta. Se o filhote não chorar, você se sentirá recompensado; entretanto, se o conteúdo da mamadeira desagrade o neném, a sensação de recompensa será menor.

Por conta dessa nova aproximação, o grafo anterior precisa ser reavaliado. Podemos agora representar o problema de uma forma distinta.



Vamos imaginar um espaço de transições em torno do estado atual, já que o estado “chorando” pode transitar para mais de um estado.

Figura 4 – Espaço das possibilidades de transição

Gritando	Arremessar	Quieto
Engatinh.	Chorando	Mamando
Afogado	Falando	Brincando

Alguns desses estados são bons, outros não são tão bons, e alguns são realmente ruins. A definição de quais deles estão em cada categoria depende do nosso entendimento cultural, que na linguagem de IA é chamado de *política do agente*. Vamos marcar os estados indesejados em vermelho.

Figura 5 – Estados indesejados para a política do agente

Gritando	Arremessar	Quieto
Engatinh.	Chorando	Mamando
Afogado	Falando	Brincando

Voltando à mamadeira: se a cria para de chorar (e entra no estado de mamando), você ganha um prêmio. No caso do MDP, esse prêmio é numérico – digamos, 20 pontos. Se o conteúdo da mamadeira desagrada o neném, mas ele entra no estado “quieto”, você ganha apenas 5 pontos. Se a criança abandona a mamadeira e passa a engatinhar, brincar, ou volta a dormir, você ganha 10 pontos. Porém, se o pequeno arremessa o vasilhame no tapete próximo (estado “arremessar”), a sua pontuação será negativa. O mesmo acontece se o choro se transforma em gritos desesperados (estado “gritando”) ou se o pequeno se afoga (estado “afogado”).

Abstraindo os estados concretos, podemos descrever o espaço de estados apenas com base nas recompensas, como na figura a seguir.



Figura 6 – Recompensas de transição

-5	-10	5
10		20
-10	10	10

Vamos aproveitar ainda mais o exemplo do bebê. Imagine que o seu objetivo seja, ao final do dia, dormir em paz, ao mesmo tempo em que a criança. O estado “dormindo” está fora do ambiente de tarefa. Porém, podemos alcançá-lo por qualquer caminho diferente. Existem vários caminhos possíveis, mas alguns devem ser evitados.

Podemos levar o lactente, depois que ele acorda chorando, para o estado “mamando” e depois “brincando”, e então aguardar que adormeça. Acumulamos, assim, 30 pontos de recompensa. Porém, se a criança, aos prantos, cansa de tanto gritar e adormece, a nossa recompensa total será negativa: -5 pontos.

Intuitivamente, combinamos as recompensas (R_i) entre o estado inicial (atual) “chorando” e o estado destino (final) “dormindo”. Essa combinação nos permite, a partir das recompensas, encontrar o caminho mais vantajoso, abstraindo da realidade do ambiente. Vamos agora conferir formalismo a esse procedimento, que acabamos de adotar intuitivamente.

TEMA 5 – UTILIDADE E VALOR DE ESTADO

No tópico anterior, estudamos como as recompensas podem qualificar as tomadas de decisão, permitindo ao agente avaliar a política atual ou comparar políticas. Também percebemos que o valor instantâneo da recompensa não é capaz de traduzir a eficiência da política como um todo. Ao final do tópico, concluímos que é interessante somar recompensas. Neste tópico, portanto, vamos chamar essa soma de *utilidade* e entender como encontrar uma política ótima pode resolver o problema de Markov.

5.1 Conceito de utilidade



Observamos que o conceito de recompensa está ligado a cada transição que o agente executa no ambiente. Também entendemos que faz sentido, percorrido um caminho entre estados quaisquer, somar as recompensas obtidas.

Ainda considerando o mesmo exemplo anterior: antes de atingir o seu sonolento objetivo final, o dia é longo, em sua convivência hipotética com a criança. Vários caminhos podem ser percorridos entre o estado atual e o distante objetivo. Diferentes atitudes, ou ações, podem gerar recompensas maiores, menores ou negativas (punições). Ao final do dia, você poderá verificar o seu score. Um valor alto pode significar que você tem grande utilidade como cuidador de seu herdeiro, já um valor negativo...

A equação que define a utilidade será composta pela soma das recompensas, que chamaremos de $R(s_i)$. Aqui, s_i define uma transição para o estado i .

$$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + R(s_1) + R(s_2) + \dots$$

Essa equação funciona bem para políticas de agentes ditas *próprias*. **Políticas próprias** são aquelas para as quais existe um estado inicial e um final, definidos e alcançáveis. Políticas impróprias, quando o agente segue agindo sobre o meio indefinidamente, apresentam U_h infinito. Para esses casos, podemos pensar na equação anterior de forma mais genérica. Se acrescentamos um fator de desconto γ para cada recompensa, podemos ponderar dadas recompensas mais do que outras. A equação seria a seguinte:

$$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots,$$

Seguindo em nosso exemplo do bebê, imagine que, em um longo dia de cuidados com o seu herdeiro, as atitudes tomadas pela manhã têm menos efeito sobre o sono noturno do lactente do que aquelas tomadas na proximidade dessa hora de descanso conjunto. As recompensas descontadas evidenciam, assim, um apreço maior por ações mais recentes (lembre-se do teorema de Markov), em comparação às mais antigas.

Por outro lado, podemos olhar a equação no sentido oposto, tomando s_0 como o estado atual, s_1 como o anterior mais recente, e assim sucessivamente. Seria possível, ainda, utilizar a formulação para fazer o agente preferir as



recompensas atuais em relação ao futuro. Segundo Norvig (2013, p. 566), o “fator de desconto descreve a preferência de um agente por recompensas atuais sobre recompensas futuras. Quando γ é próximo de 0, as recompensas no futuro distante são vistas como insignificantes”. De qualquer forma, em políticas impróprias, o acréscimo de γ permite fazer com que o valor da utilidade U seja mensurável.

Agora, vamos dar um passo importante para o cálculo do valor de um dado estado, dito **valor do estado** ou **utilidade esperada**.

Já concluímos que a utilidade de um estado atual pode ser calculada pela soma das recompensas que conduziram até esse estado, ou que são capazes de conduzir até o estado de destino. Se desejamos calcular a utilidade esperada de um estado futuro qualquer, podemos obter esse valor pela soma das recompensas esperadas até chegar àquele estado, desde que cumprida a política π do agente. Assim, se designamos a esperança matemática como E , podemos escrever:

$$U^\pi(s) = E \left[\sum_{t=0}^{\infty} \gamma^t R(S_t) \right]$$

Dessa forma, um estado s_i terá valor 0,2 (por exemplo) se a soma das recompensas esperadas até chegar àquele estado for 0,2. Um estado com maior valor de U será um estado melhor para o agente do que um outro com U menor.

Outra conclusão possível é que uma política π_1 , que conduza, após um tempo t , do estado atual s_i ao estado desejado, com valor U_1 , é melhor que a política π_2 , que conduz ao mesmo estado, no mesmo intervalo t , com valor U_2 , se $U_1 > U_2$. Assim, conceituaremos $V^\pi(s)$ como o valor de um estado, dado que cumpre a programação, ou política, π .

A utilidade $U^\pi(s)$ é normalmente calculada no sentido passado para a designação a partir de um estado inicial, considerando a expectativa de recompensas até alcançar o estado final, seguindo dada política. Já o valor do estado $V^\pi(s)$ designa a expectativa de recompensa do estado presente s_i até outro estado s_j . Podemos, guardada essa sutil diferença, afirmar que numericamente:

$$V^\pi(s) = U^\pi(s)$$



Voltando ao nosso exemplo do bebê: com a sequência dos dias, você será capaz, com base nas recompensas, de intuir a melhor forma de maximizar o seu score. Suponha que, em um determinado dia, com base em certas atitudes (política π_1), você obteve utilidade 0,7 até o final do dia. Em outro dia, tomando outras atitudes (política π_2), você obteve 0,5. Assim, política π_1 é melhor do que a política π_2 .

5.2 Solução do MDP

Já vimos que cada política pode conduzir a uma utilidade diferente. O problema proposto por Markov é justamente encontrar a política ótima, ou seja, aquela combinação de ações que conduz o agente do estado i para o estado j , com a maior somatória de recompensas – ou, como definimos, com a maior utilidade possível.


Para fazer esse cálculo, precisamos de uma equação que relacione as políticas com as suas utilidades. Então, iremos buscar o ponto de máximo por uma técnica algébrica qualquer, como a derivação.

A equação que relaciona essas grandezas é a equação de Bellman, proposta pelo americano Richard Bellman. Esse matemático introduziu a chamada *programação dinâmica*, com técnicas iterativas para a solução do problema de otimização da cadeia de Markov.

Bellman calculou o valor de cada estado possível ao agente a partir do último estado, ou estado destino. O cálculo é feito, de modo geral, determinando a máxima recompensa para o estado destino, s_d . A partir de s_d , verificamos os estados adjacentes que conduzem a ele, s_{d-1} . A cada um desses estados adjacentes conferimos um valor baseado na recompensa descontada do estado de destino. Assim, esse processo é iterativo para os estados s_{d-2} , ou seja, aqueles estados adjacentes aos estados s_{d-1} (Bellman, 1954). A figura a seguir ilustra o processo.



Figura 7 – Cálculo de V_i iterativo segundo proposto por Bellman




Desta forma, um agente poderia guiar as suas ações unicamente pela análise dos valores dos estados adjacentes ao estado atual, seguindo o paradigma proposto por Markov, em busca da recompensa final R_f .

Vamos a um exemplo. Suponha que o agente se encontra no estado “ $s_{2,1}$ ”, localizado na linha 2, coluna 1 da figura. Mover-se para baixo leva ao estado “ $s_{3,1}$ ”, que não tem valor, mas mover-se para cima, “ $s_{1,1}$ ”, coloca o agente em um estado com valor 0,9. Assim, essa será a decisão markoviana do agente. O mesmo ocorre se o agente se movimentar para “ $s_{2,2}$ ”, para um estado de valor 0,9. Qual deve ser a decisão?

A multiplicidade de trajetos é própria de ambientes não determinísticos, e assim só pode ser definida de forma unívoca se temos mais dados sobre o estado. Como nesse exemplo só temos o valor do estado, o agente poderá tomar qualquer uma das duas decisões. A figura a seguir ilustra o caminho.

Figura 8 – Caminho do agente em busca da recompensa R_f





Seguindo no exemplo: se o agente está em " $s_{1,1}$ " a decisão será mover-se para " $s_{1,2}$ " uma vez que esse movimento leva o agente para um estado de maior valor. Em " $s_{1,2}$ ", o agente irá para " s_d ", recebendo a recompensa. Naturalmente, a compreensão completa dos cálculos envolvidos e da teoria de suporte exige um pouco mais de detalhamento. De qualquer forma, já podemos entender como solucionar a questão de otimização da política do agente.

FINALIZANDO

Nesta etapa, buscamos construir o entendimento do método de Markov, que soluciona problemas de aprendizado em ambientes estocásticos, como no caso da aprendizagem por reforço. Ainda não somos plenamente capazes de resolver o problema da otimização da política do agente, que é a solução proposta por Bellman para treinar o agente de forma eficiente. Futuramente, vamos estudar as possibilidades de solução, iniciando o nosso caminho em direção à aplicação computacional desses conceitos.



REFERÊNCIAS

BELLMAN, R. Some applications of the theory of dynamic programming—a review. **Journal of the Operations Research Society of America**, v. 2, n. 3, p. 275-288, 1954.

COPPIN, B. **Inteligência artificial**. São Paulo: Grupo Gen, 2010.

HAYKIN, S. **Redes neurais**: princípios e práticas. Porto Alegre: Bookman, 2011.

NETO, P. L. de O. C. **Probabilidades**. São Paulo: Blucher, 2006.

NORVIG, P. **Inteligência artificial**. São Paulo: Grupo Gen, 2013.

ROSS, S. **Probabilidade**. Porto Alegre: Bookman, 2010.

.